Probabilidad

Aplicación: Regresión Logística

Sergio A. Cantillo

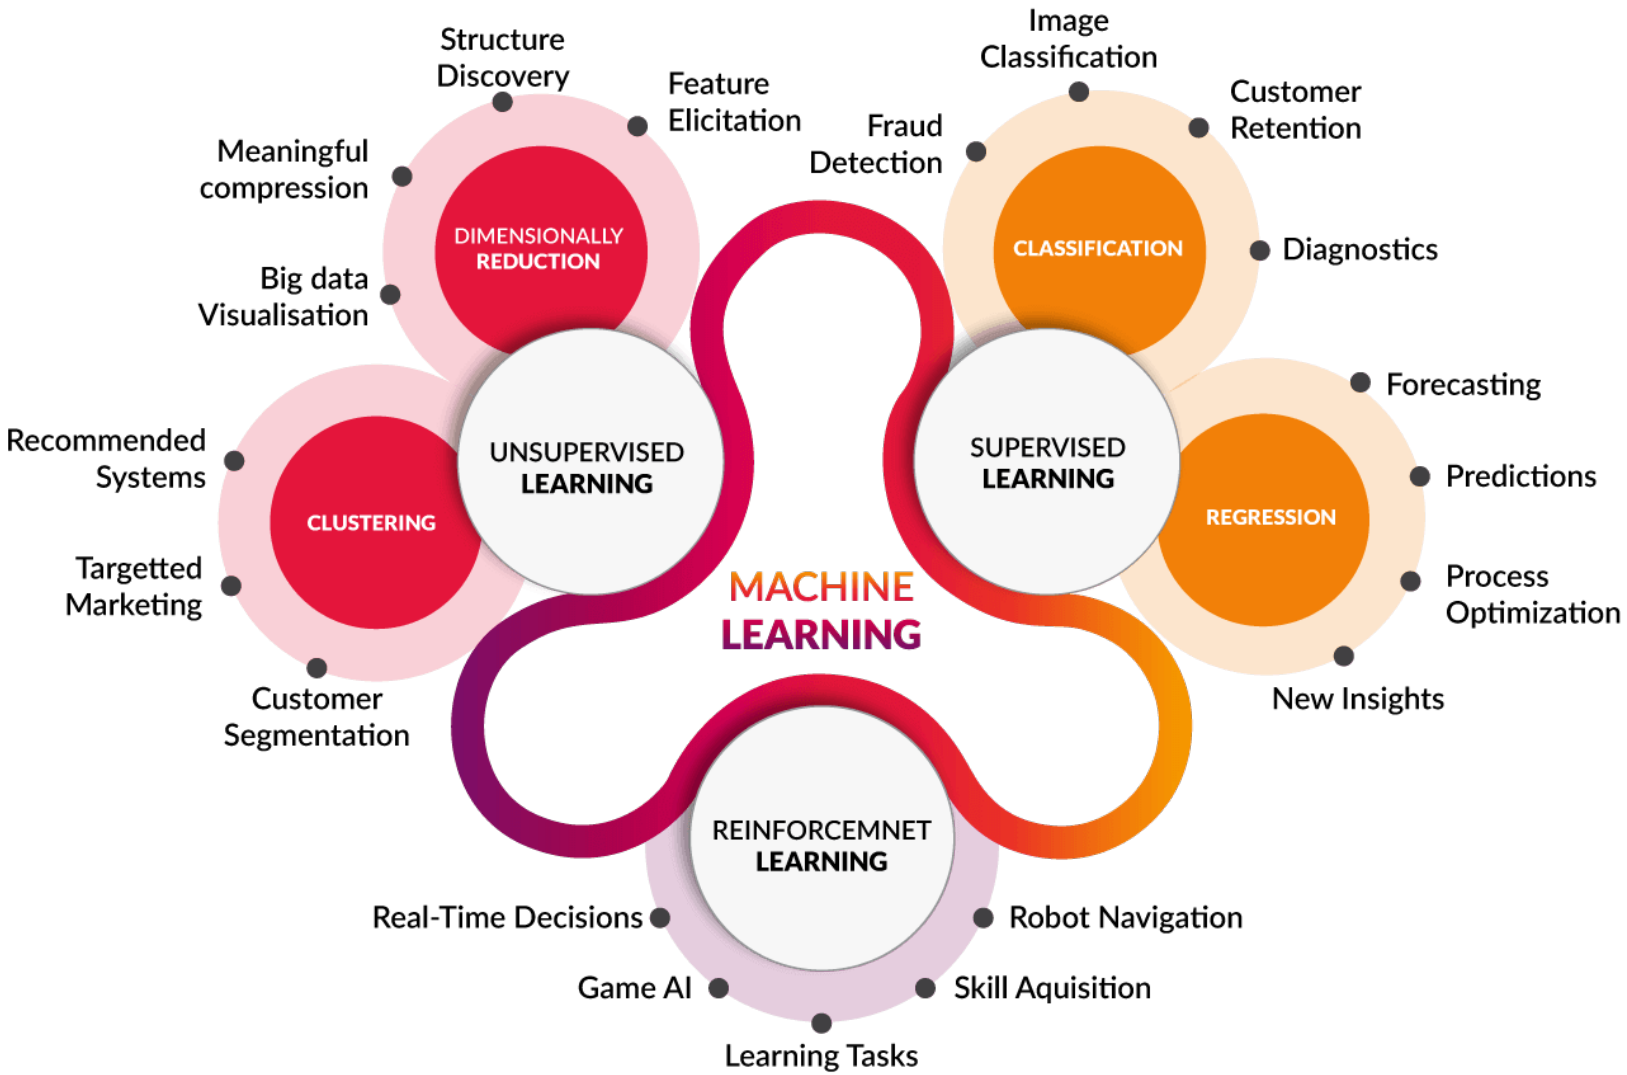
sacantillo@uao.edu.co

Facultad de Ingeniería y Ciencias Básicas
Universidad Autónoma de Occidente

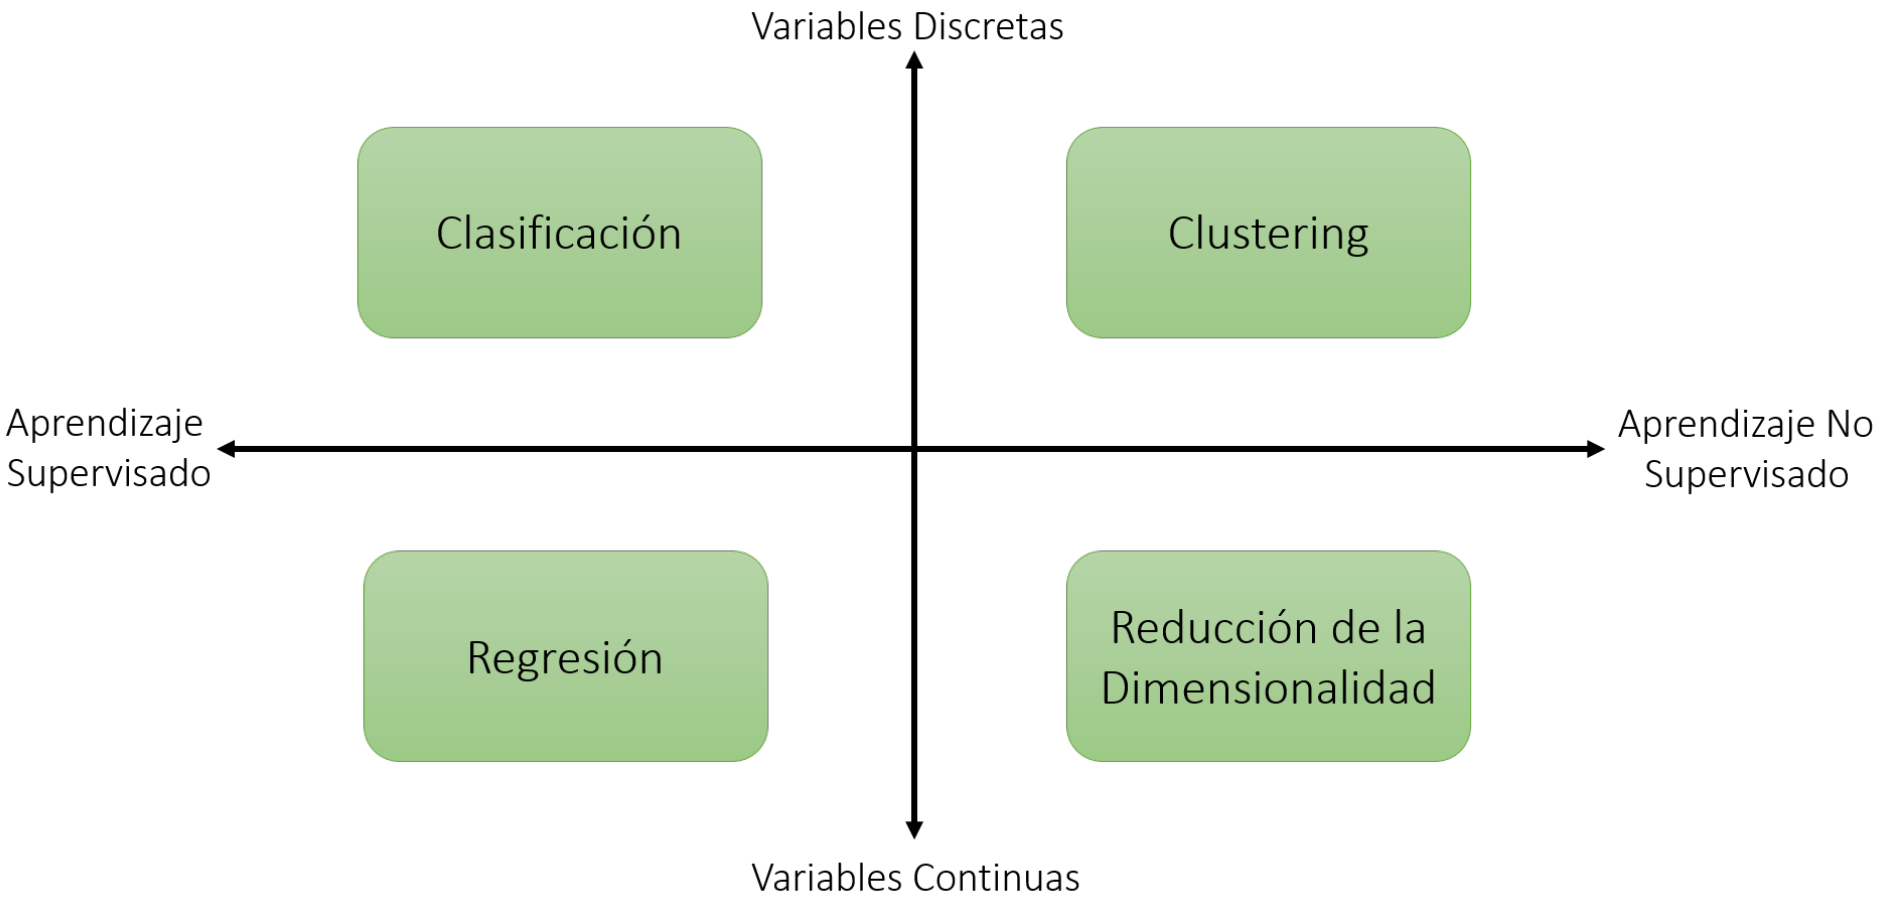
Agenda

1. Contexto
   - Clasificación
   - Tipos de Clasificación
   - Medidas de Rendimiento
2. Algoritmos de Clasificación
   - Regresión Logística
3. Referencias

Contexto ML


MACHINE LEARNING
UNSUPERVISED LEARNING
SUPERVISED LEARNING
REINFORCEMNET LEARNING
DIMENSIONALLY REDUCTION
CLUSTERING
CLASSIFICATION
REGRESSION
Structure Discovery
Feature Elicitation
Meaningful compression
Big data Visualisation
Image Classification
Customer Retention
Fraud Detection
Diagnostics
Recommended Systems
Targetted Marketing
Customer Segmentation
Forecasting
Predictions
Process Optimization
New Insights
Real-Time Decisions
Robot Navigation
Game AI
Skill Aquisition
Learning Tasks

Tareas de ML/DL segun tipo de dato y aprendizaje



Agenda

1. Contexto
   - Clasificación
   - Tipos de Clasificación
   - Medidas de Rendimiento
2. Algoritmos de Clasificación
   - Regresión Logística
3. Referencias

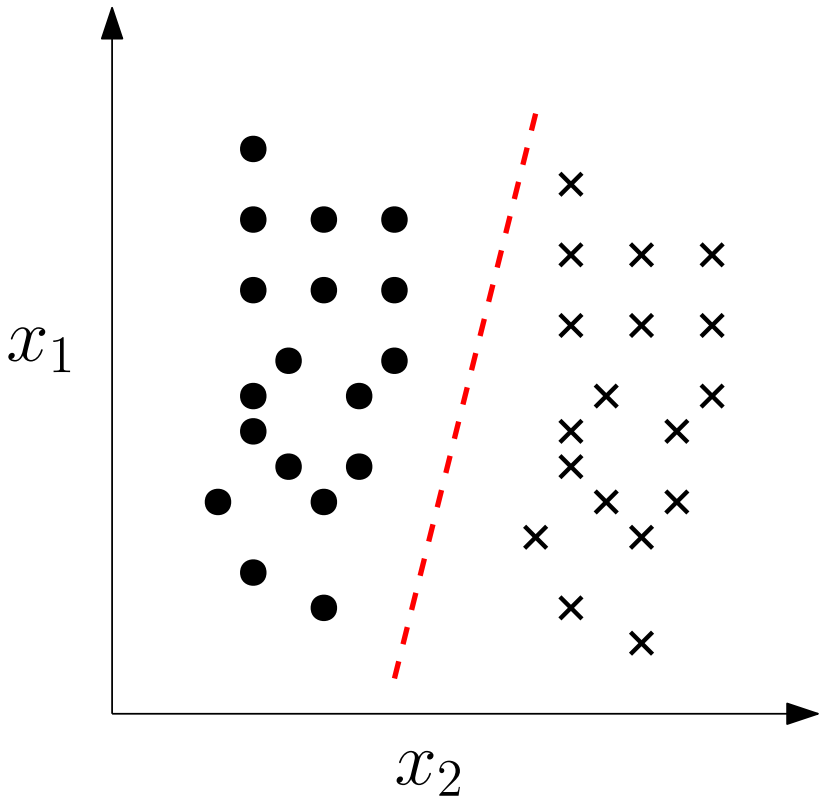
Problemas de Clasificación

- La clasificación es una tarea de aprendizaje supervisado, donde el objetivo es predecir resultados con valores discretos (**variables categóricas o etiquetas**).
- Con base en conjuntos de datos pasados de una o mas variables predictoras, se busca que un modelo de clasificación ajuste/aprenda una función que permita la generalización de predecir correctamente la variable dependiente discreta. A los posibles valores de esta variable, se les conoce como **categorías** o **clases**. Geométricamente, quiere decir que se busca generar lineas/planos que dividan entre los distintos tipos de dato.

Ejemplo

Filtro de correos spam.
Podemos entrenar un modelo con un lote de correos electrónicos etiquetados debidamente como spam y no spam para predecir si un nuevo correo que llega pertenece a una categoría o la otra.

Planteamiento de la clasificación



Datos:

- Clase 0: círculos.
- Clase 1: cruces.
- 18 datos(muestras de entrenamiento) para cada una de las clases.

Nota

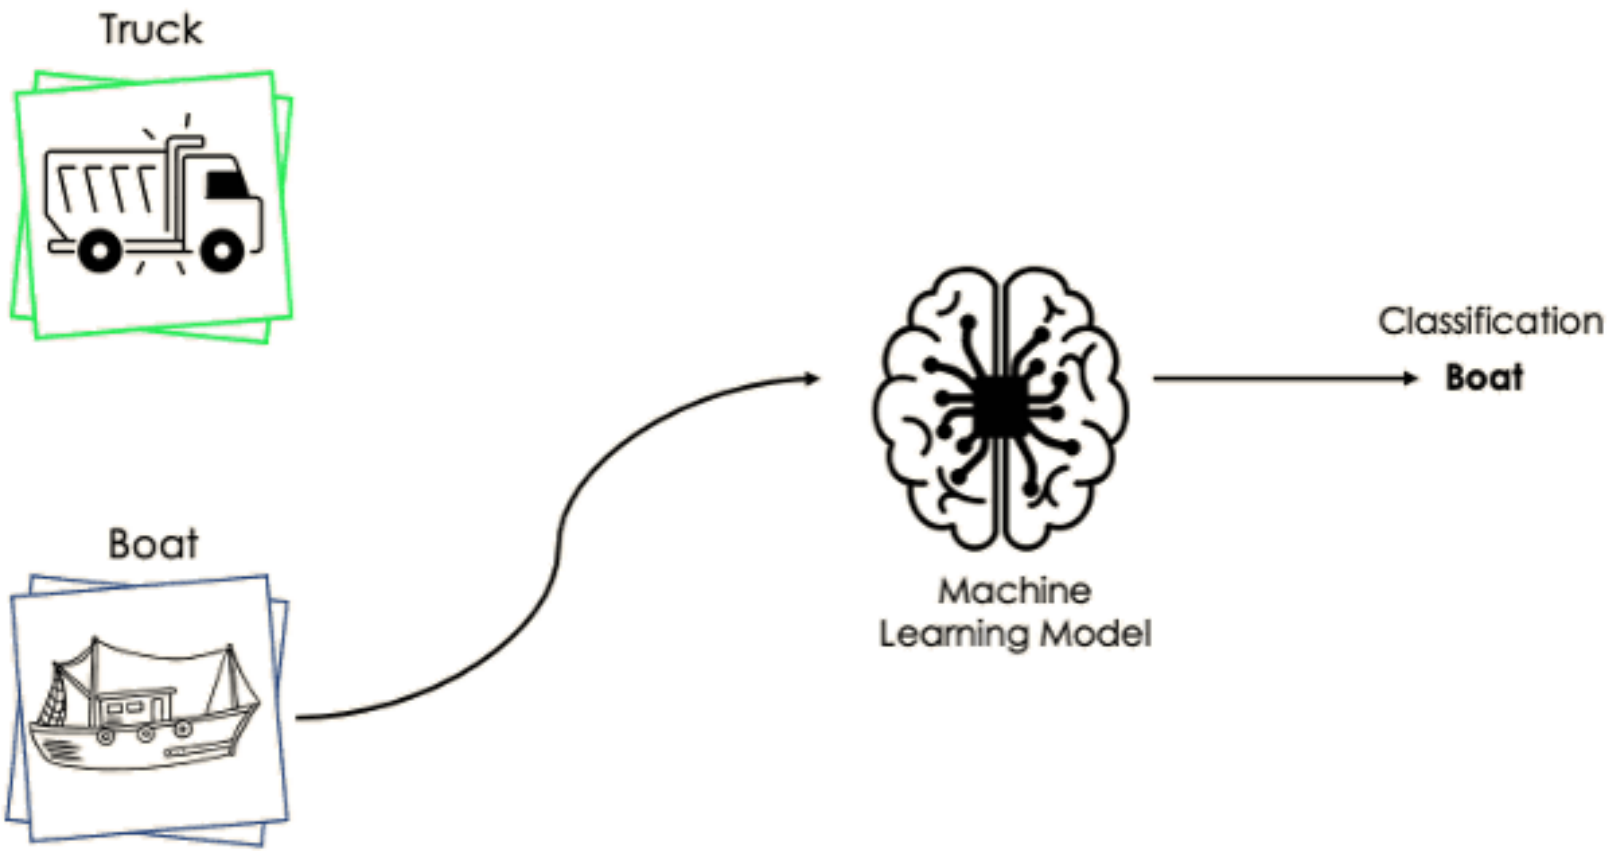
La clasificación considera la clase/etiqueta 0 como la inicial. Es decir, si un modelo clasifica entre 4 elementos, las clases serán 0,1,2, y 3.

Asimismo, los gráficos ahora contrastan una división de datos a partir de sus características (x_1 y x_2 en este caso)

Agenda

1. Contexto
   - Clasificación
   - Tipos de Clasificación
   - Medidas de Rendimiento
2. Algoritmos de Clasificación
   - Regresión Logística
3. Referencias

Clasificación: Tipo de tarea I



Clasificación Binaria

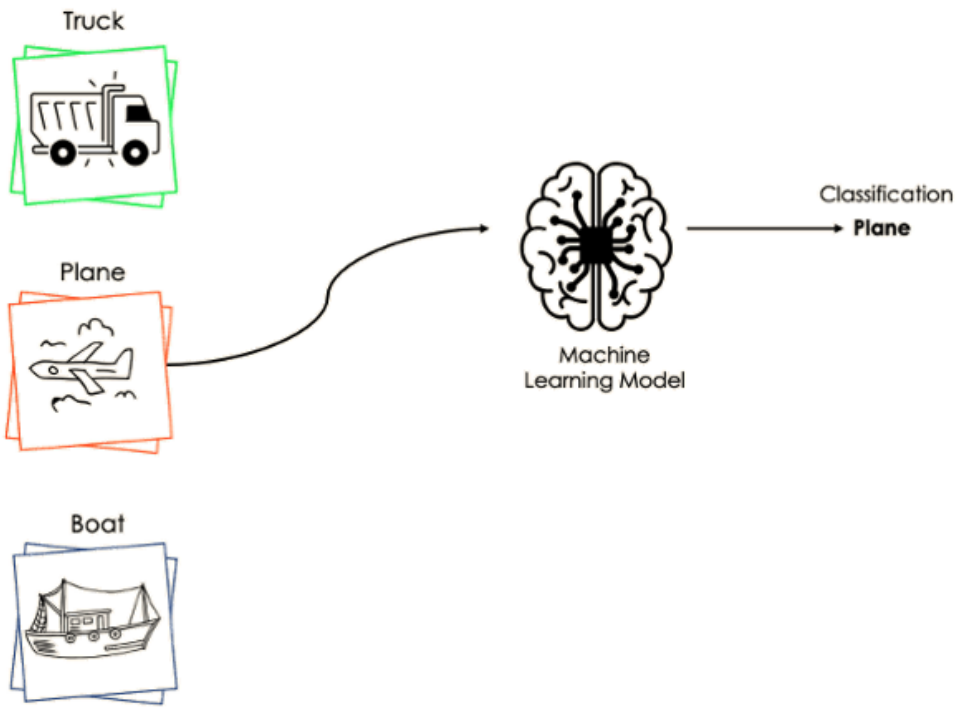
Tarea de clasificación cuyo objetivo es definir una única opción entre **dos clases mutuamente excluyentes**, por ejemplo: verdadero (1) o falso (0).

Clasificación: Tipo de tarea II

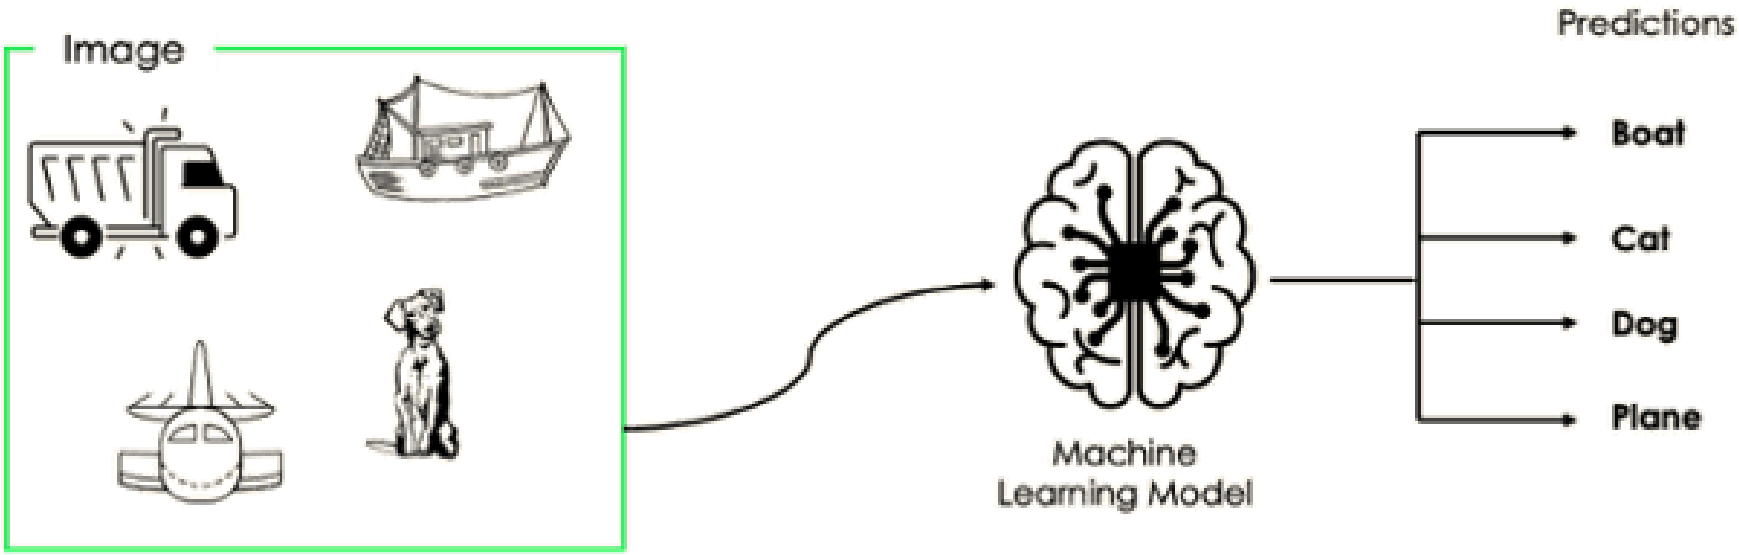
Clasificación Multiclase

Tarea de clasificación cuyo objetivo es definir una única opción entre **tres o mas clases mutuamente excluyentes**.

La mayoría de técnicas/algoritmos de clasificación binaria también se usan para esta tarea.



Clasificación: Tipo de tarea III

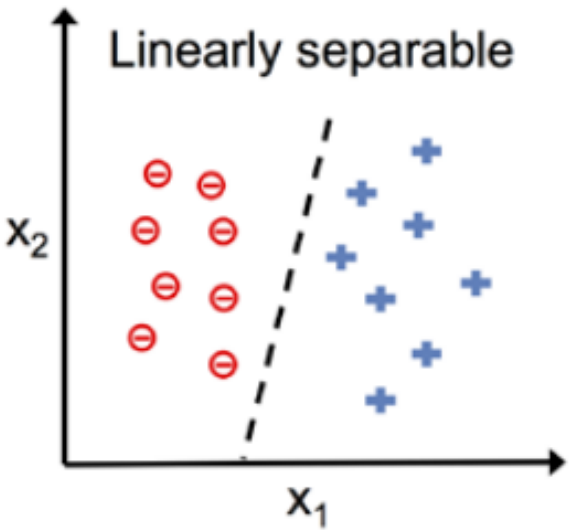


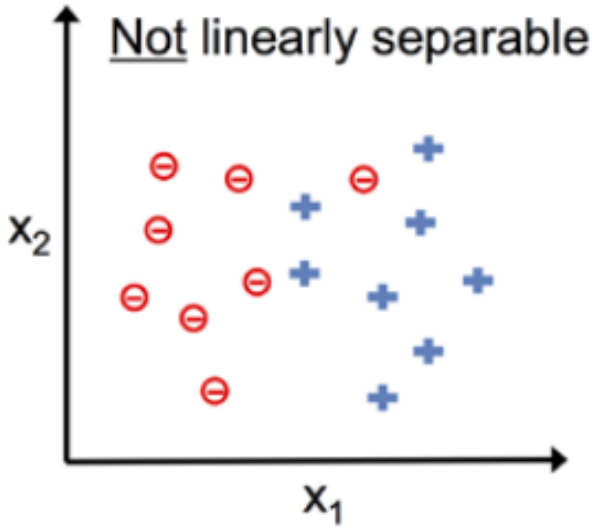
Clasificación Multi-etiqueta

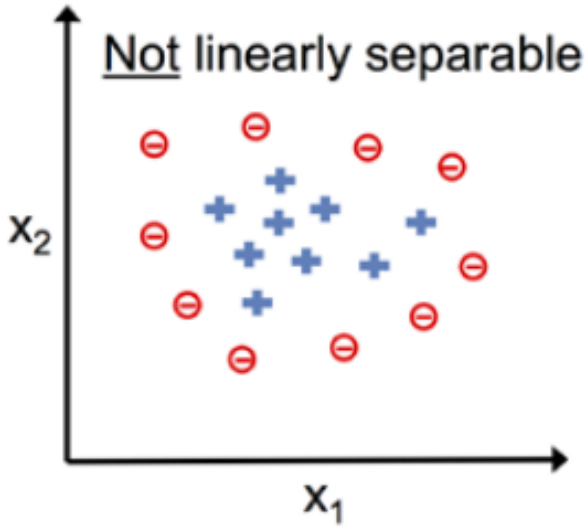
Tarea de clasificación cuyo objetivo es definir entre dos o mas clases que ya **no son mutuamente excluyente**s. Es decir, es posible encontrar 0 o mas clases en cada muestra.

Hay métodos/técnicas especializadas para este tipo de tarea.

Clasificación: Separatividad

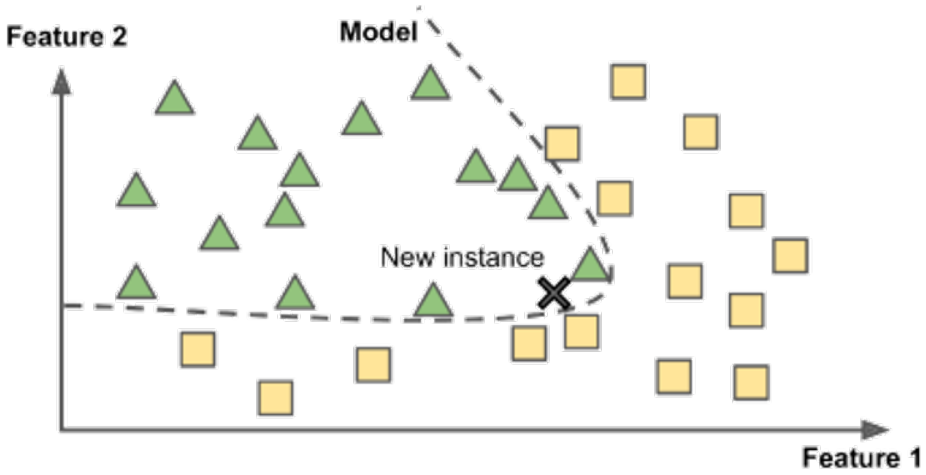






Clasificación: Tipo de aprendizaje

Aprendizaje basado en Modelo



- Perceptron
- Árboles de decisión
- SVM
- Regresión Logística

Aprendizaje basado en Instancias

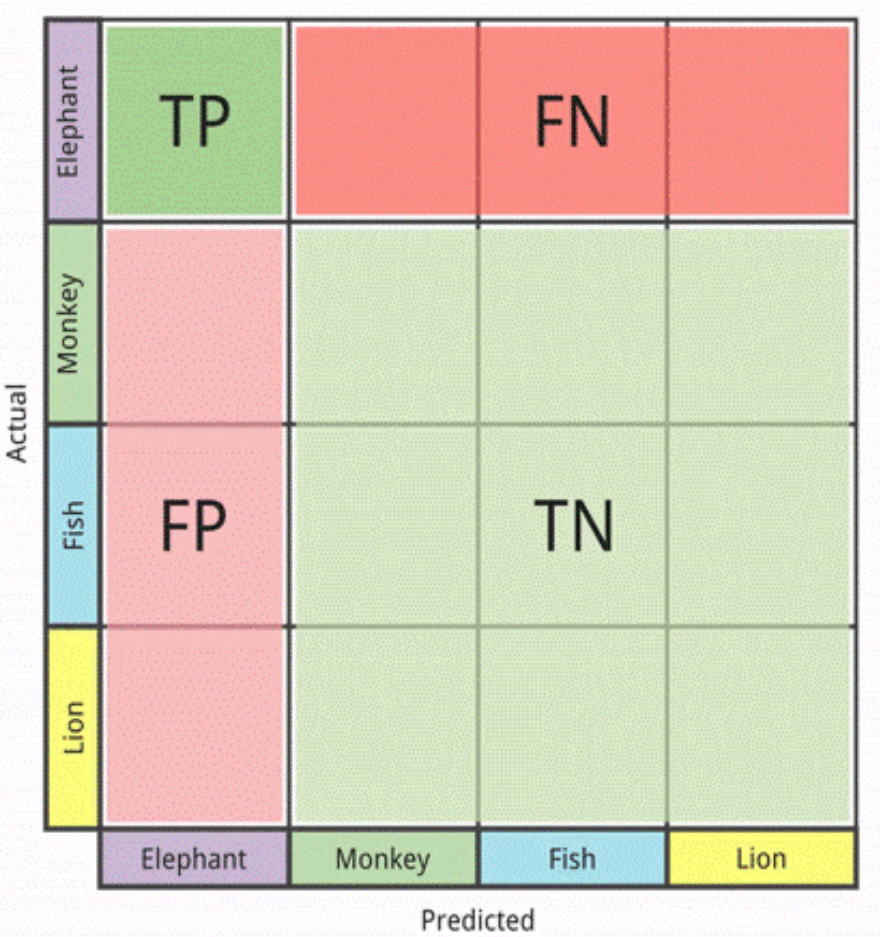


- KNN

Agenda

1. Contexto
   - Clasificación
   - Tipos de Clasificación
   - Medidas de Rendimiento
2. Algoritmos de Clasificación
   - Regresión Logística
3. Referencias

Medidas de Rendimiento I



Matriz de Confusión

- **TN:** *Verdaderos negativos*, número de datos clasificados por el modelo como negativos y son realmente negativos.
- **FP:** *Falsos positivos*, número de datos clasificados por el modelo como positivos y son realmente negativos.
- **FN:** *Falsos Negativos*, número de datos clasificados por el modelo como negativos, pero son realmente positivos.
- **TP:** *Verdaderos Positivos*, número de datos clasificados por el modelo como positivos y son realmente positivos.

Notas:

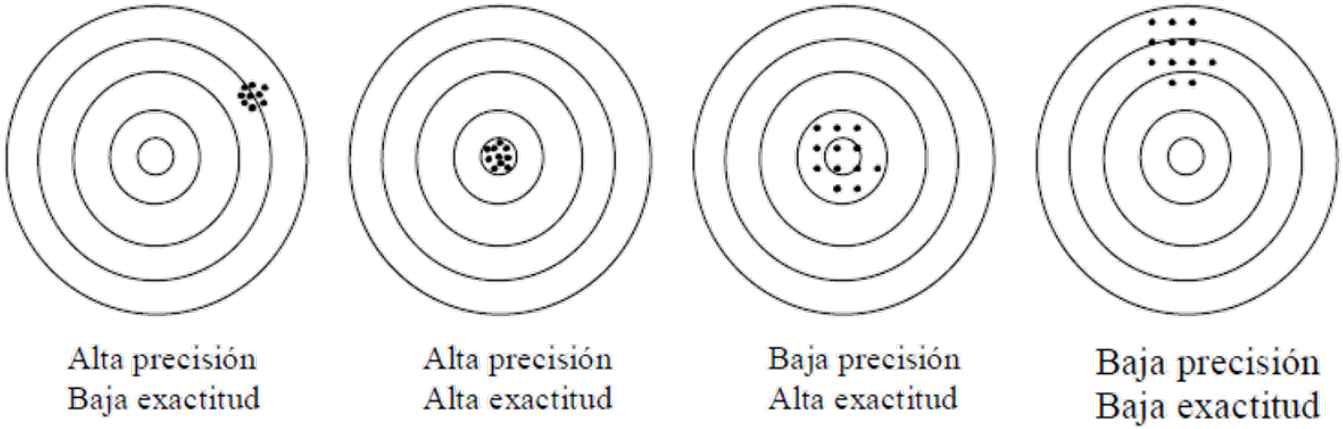
1. Tanto FP como FN, se revisan **clase por clase**.
2. Se busca que los valores entregados por los modelos estén en la diagonal principal (TP y TN).

Medidas de Rendimiento II

Accuracy (Exactitud)

Proporción de resultados correctos (TP y TN) entre todos los resultados. Medida general porcentual del rendimiento del modelo ante datasets balanceados. **Diferente a la precisión.**

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$



Medidas de Rendimiento III

Precisión (Precision)

Proporción de resultados positivos verdaderos (TP) entre todos los resultados positivos (TP + FP). Mide la calidad de las predicciones positivas.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Exhaustividad (Recall)

Proporción de resultados positivos verdaderos (TP) entre todos los casos positivos reales (TP + FN). Mide la capacidad del modelo para identificar todos los casos positivos.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Medidas de Rendimiento IV

Especificidad (Specificity)

Proporción de resultados negativos verdaderos (TN) entre todos los casos negativos reales (TN + FP). Mide la capacidad del modelo para identificar todos los casos negativos.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

Puntaje F1 (F1-Score)

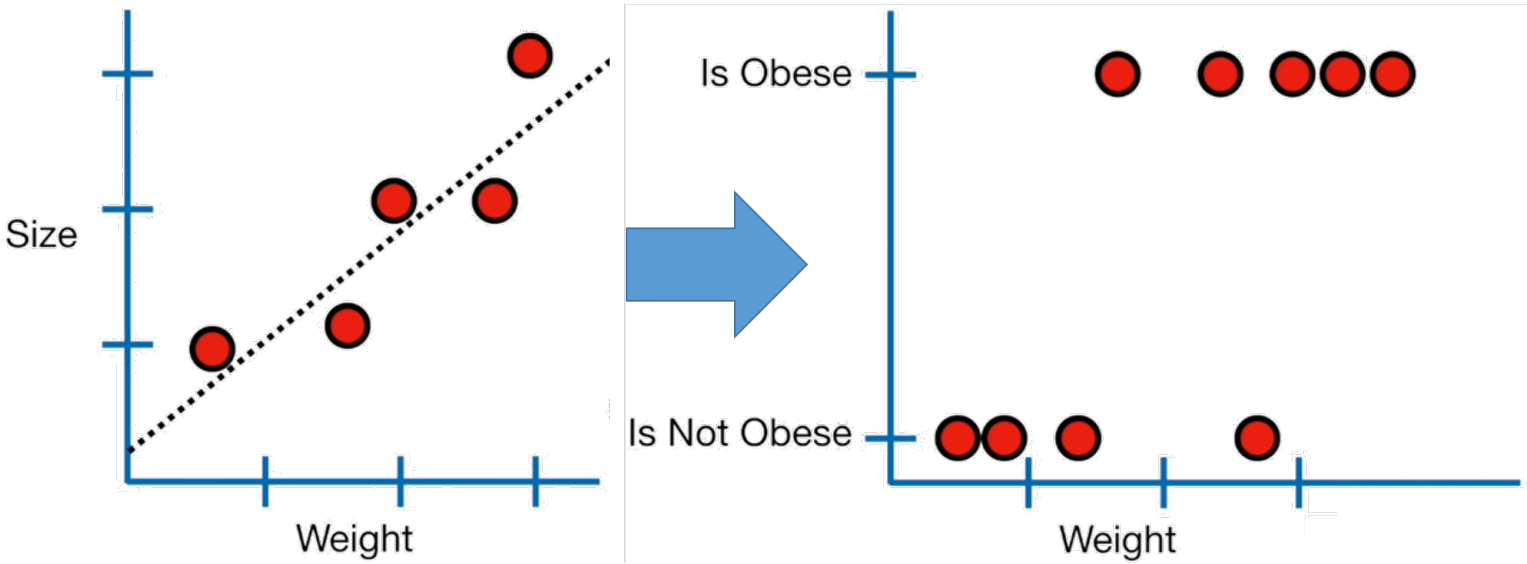
Medida de la precisión y la exhaustividad equilibrada, útil para evaluar algoritmos de clasificación en situaciones donde ambas métricas son importantes.

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Agenda

1. Contexto
   - Clasificación
   - Tipos de Clasificación
   - Medidas de Rendimiento
2. Algoritmos de Clasificación
   - Regresión Logística
3. Referencias

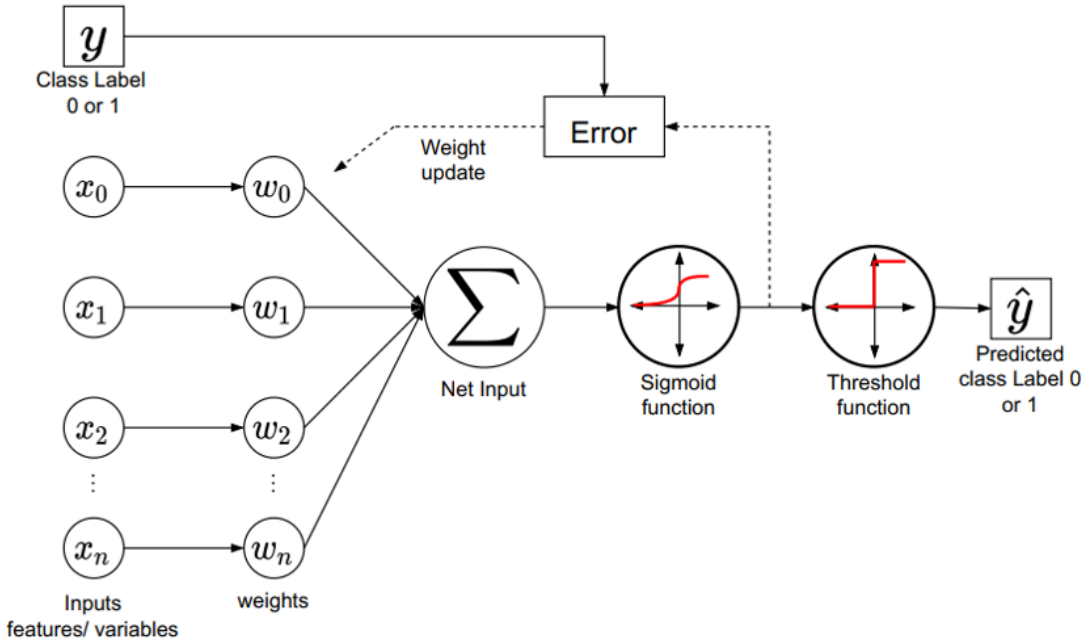
Regresión Logística I



Intuición

- Al generar una recta (un hiper-plano si hay múltiples variables), se pueden obtener valores predichos distintos de 0 y 1, lo que entra en contradicción con la definición de la variable respuesta binaria.
- Si se quiere interpretar las predicciones del modelo como probabilidades de pertenencia a cada clase, no se cumpliría la condición de que toda probabilidad ha de estar dentro del intervalo [0,1], ya que podrían obtenerse valores fuera de este.

Regresión Logística II



$$X = [x_0, x_1, \ldots, x_n]$$

$$W = [w_0, w_1, \ldots, w_n]$$

$$f(w, x) = \sum_{i=1}^{n} w_i x_i = W^T X$$

$$\hat{P}(Y = 1) = \frac{1}{1 + e^{-f(x,w)}} = \sigma(t)$$

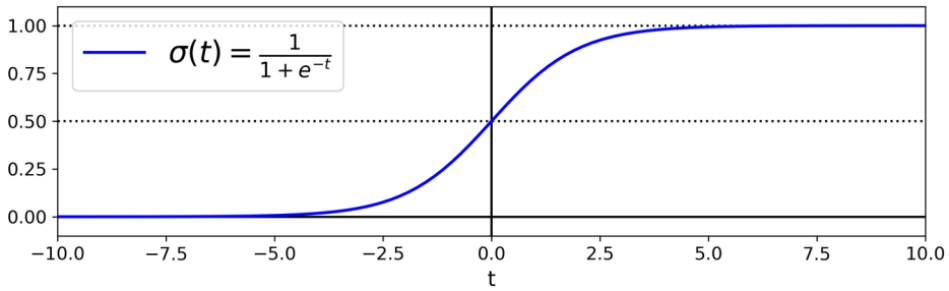
Definición

La regresión logística es un método estadístico que busca modelar la **probabilidad de pertenencia** a una variable cualitativa binaria (dos posibles valores) en función de una o más (softmax) variables independientes.
Notacion O (Complejidad): $O(n_{epocas} \cdot samples \cdot features)$

Regresión Logística III

Funcion Sigmoide

$$\hat{p} = h_{\boldsymbol{W}}(\boldsymbol{X}) = \frac{1}{1 + e^{-t}} = \sigma(t)$$



$$\hat{p}(y = 1|X = x) = \frac{e^{w_0 + w_1 x_1 + \ldots + w_p x_p}}{1 + e^{w_0 + w_1 x_1 + \ldots + w_p x_p}}$$

La Regresión Logística recibe una combinación lineal de las características como entrada (tal como en la regresión lineal) y genera como salida un valor numérico entre 0 y 1. Luego este valor es evaluado en un función umbral o **THRESHOLD**.

$$\hat{y} = \begin{cases} 0 & \text{if } \hat{p} < 0{,}5 \\ 1 & \text{if } \hat{p} \geq 0{,}5 \end{cases}$$

Regresión Logística IV

Supuestos

- La relación entre las características y el logaritmo de la razón de probabilidad es lineal.
- Las observaciones son **independientes** entre sí, lo que significa que el resultado de una observación no afecta el resultado de otra.
- Se debe evitar la multicolinealidad. Aumenta la difícultad de interpretación de los coeficientes de regresión.

Regresión Logística V

Consideraciones

- A veces, es necesario transformar las variables independientes para cumplir con el supuesto de linealidad.
- En algunos casos, puede ser beneficioso aplicar técnicas de regularización, como L1 o L2.
- Los coeficientes se interpretan en términos de cambios en las probabilidades logarítmicas.
- Si las clases están desequilibradas, es importante considerar técnicas de muestreo o ponderación (balanceo) al usar RegLog.

Regresión Logística VI

Algoritmo de Aprendizaje

- La función de costo para la regresión logística es una función probabilística.

$$L(\boldsymbol{w}) = P(\boldsymbol{y}|\boldsymbol{x};\boldsymbol{w}) = \prod_{i=1}^{n} P(y^{(i)}|\boldsymbol{x}^{(i)};\boldsymbol{w}) = \prod_{i=1}^{n} (\sigma(z^{(i)}))^{y^{(i)}} (1-\sigma(z^{(i)}))^{1-y^{(i)}}$$

- La función de costo es convexa, lo cual garantiza que el Gradiente Descendente (se ajustan la tasa de aprendizaje e iteraciones) puede encontrar el mínimo global. No existe un método analítico (OLS) para este tipo de regresión.

$$J(\boldsymbol{w}) = \log L(\boldsymbol{w}) = -\frac{1}{m} \sum_{i=1}^{m} [y^{(i)} \log(\hat{p}^{(i)}) + (1-y^{(i)}) \log(1-\hat{p}^{(i)})]$$

- La función de costo para una sola **muestra** del conjunto de datos:

$$J(\boldsymbol{w}) = \begin{cases} -\log(\hat{p}) & \text{if } y = 1 \\ -\log(1-\hat{p}) & \text{if } y = 0 \end{cases}$$

Ejemplo

- Predecir si una persona jugará al golf en función de las condiciones climáticas.

Training Set

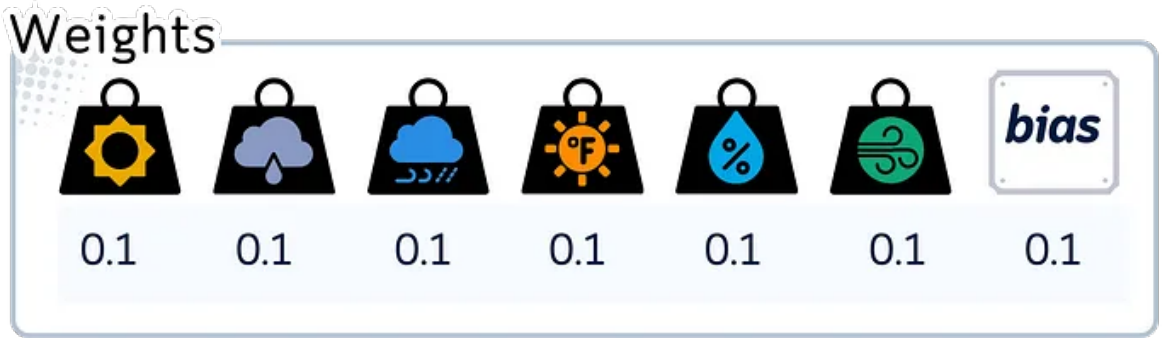
0	1	0	0	1.80	0.50	0	No
1	1	0	0	1.02	1.02	1	No
2	0	1	0	1.49	-0.24	0	Yes
3	0	0	1	-0.56	1.66	0	Yes
4	0	0	1	-0.88	-0.03	0	Yes
5	0	0	1	-1.35	-1.08	1	No
6	0	1	0	-1.51	-1.61	1	Yes
7	1	0	0	-0.25	1.55	0	No
8	1	0	0	-0.72	-1.08	0	Yes
9	0	0	1	0.23	-0.03	0	Yes
10	1	0	0	0.23	-1.08	1	Yes
11	0	1	0	-0.25	1.02	1	Yes
12	0	1	0	1.17	-0.56	0	Yes
13	0	0	1	-0.41	-0.03	1	No

Test Set

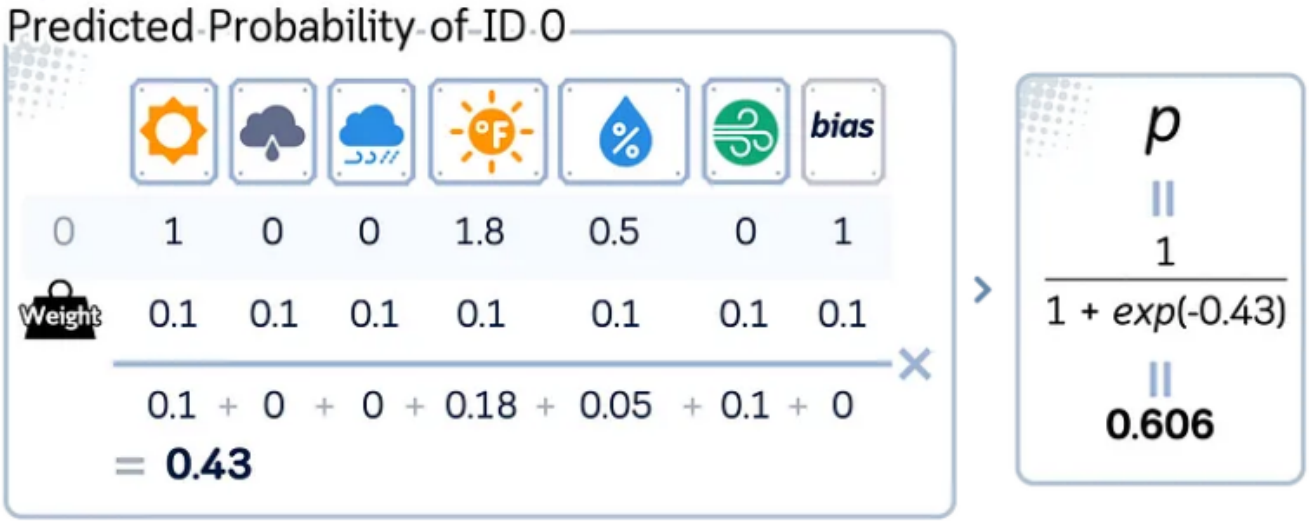
14	1	0	0	1.17	0.81	1	No
15	0	0	0	0.07	1.24	0	Yes
16	0	1	1	0.38	0.50	0	Yes
17	1	0	0	0.70	-0.56	1	No
18	1	0	0	1.33	1.24	0	No
19	0	1	1	-1.04	1.02	1	No
20	0	0	0	1.80	0.50	1	Yes
21	0	1	1	-0.09	0.81	0	Yes
22	1	0	0	2.28	-1.61	1	Yes
23	0	0	0	0.54	-1.08	0	Yes
24	1	0	0	0.86	-2.14	0	Yes
25	0	0	0	1.02	1.55	1	Yes
26	0	1	1	-1.20	-1.08	0	No
27	0	0	0	1.65	-0.24	0	Yes

Ejemplo

- **Paso 1:** Inicializar los parámetros (valores aleatorios pequeños).

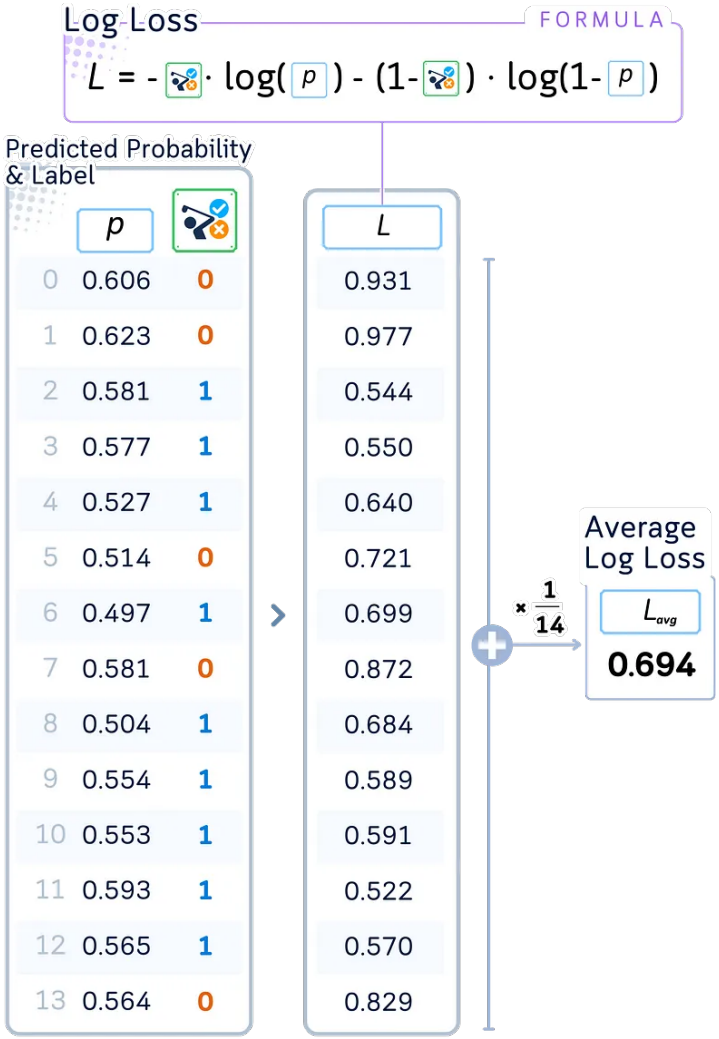


- **Paso 2:** Para cada muestra de entrenamiento:
  - Calcule la probabilidad predicha usando los parámetros iniciales.



Ejemplo

- **Paso 2:** Para cada muestra de entrenamiento:
  - Comparar la probabilidad con la etiqueta de clase real usando la función de pérdida.



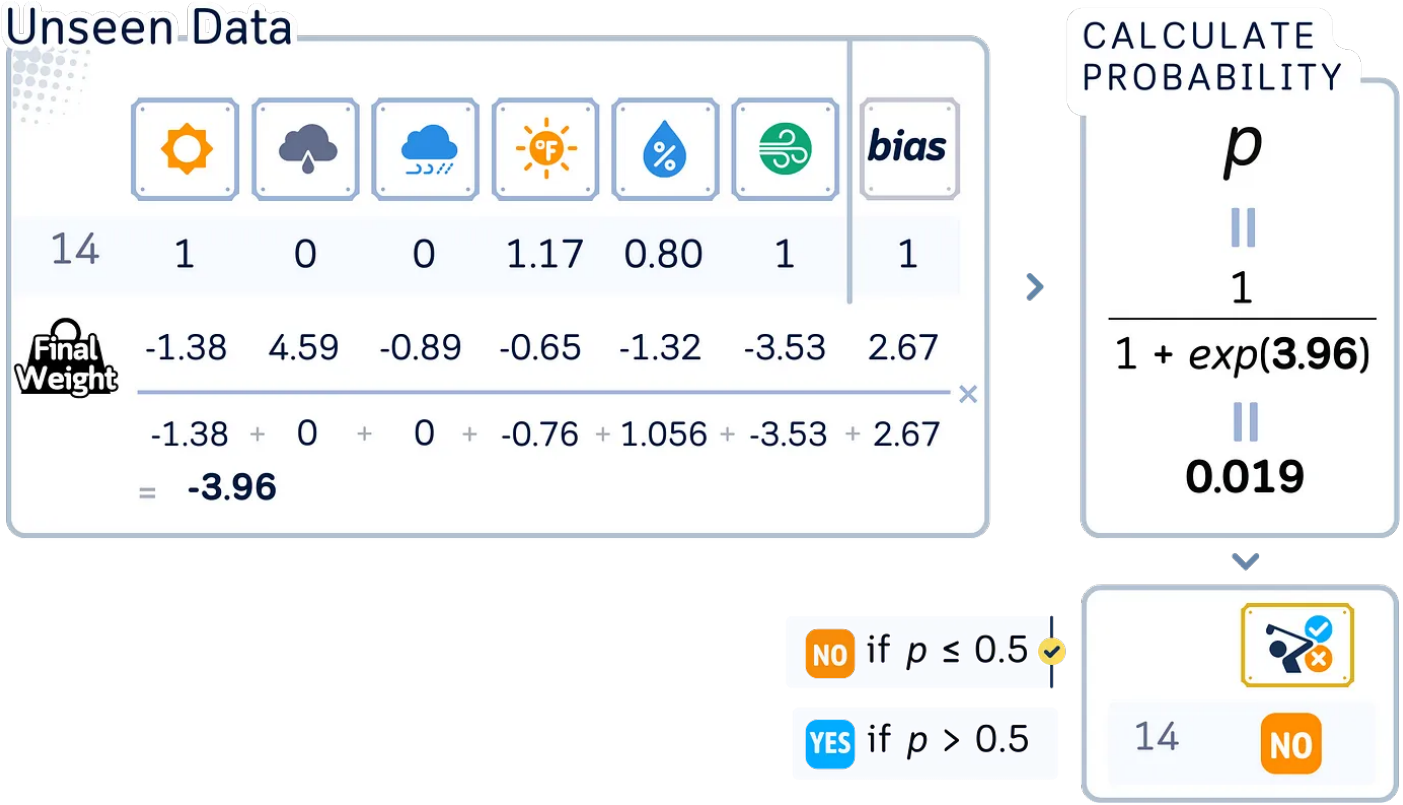
Ejemplo

- **Paso 3:** Actualizar los pesos para minimizar la pérdida (descenso de gradiente). Esto incluye hacer repetidamente el Paso 2 hasta que la pérdida de registro no pueda reducirse mas - convergencia).



Ejemplo

- **Nuevas Instancias:** Calcular la probabilidad con los pesos finales (también llamados coeficientes), al igual que durante el paso de entrenamiento. Luego, interpretar la salida viendo la probabilidad: si $p \geq 0{,}5$ predice la clase 1; de lo contrario, predice la clase 0.



Referencias

https://www.probabilitycourse.com/

http://web.stanford.edu/class/archive/cs/cs109/cs109.1192/handouts/pythonForProbability.html

https://towardsdatascience.com/logistic-regression-explained-a-visual-guide-with-code-examples-for-beginners-81baf5871505