Cálculo

Aplicación: Regresión (Machine Learning)

Sergio A. Cantillo

sacantillo@uao.edu.co

Facultad de Ingeniería y Ciencias Básicas
Universidad Autónoma de Occidente

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Agenda

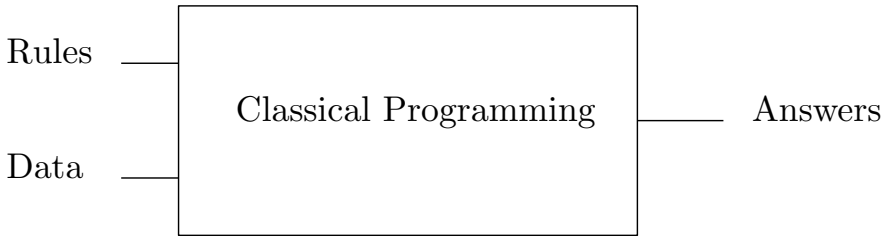
1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

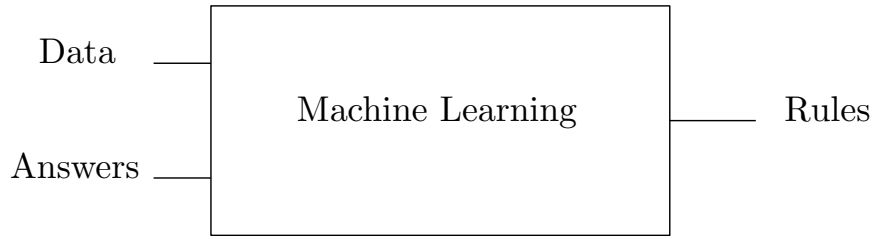
Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Machine Learning

Aprendizaje Automático: Un nuevo paradigma de programación





- Los humanos introducen reglas (un programa) y datos para ser procesados acorde con dichas reglas.
- Las respuestas se obtienen a la salida del programa.

- Los humanos introducen datos como entrada al igual que las respuestas esperadas de dichos datos.
- Las reglas se obtienen a la salida del programa.
- Las reglas pueden ser luego aplicadas a nuevos datos para respuestas originales, es decir, generadas automaticamente por las reglas que el sistema aprende y no por las reglas que el programador defina.

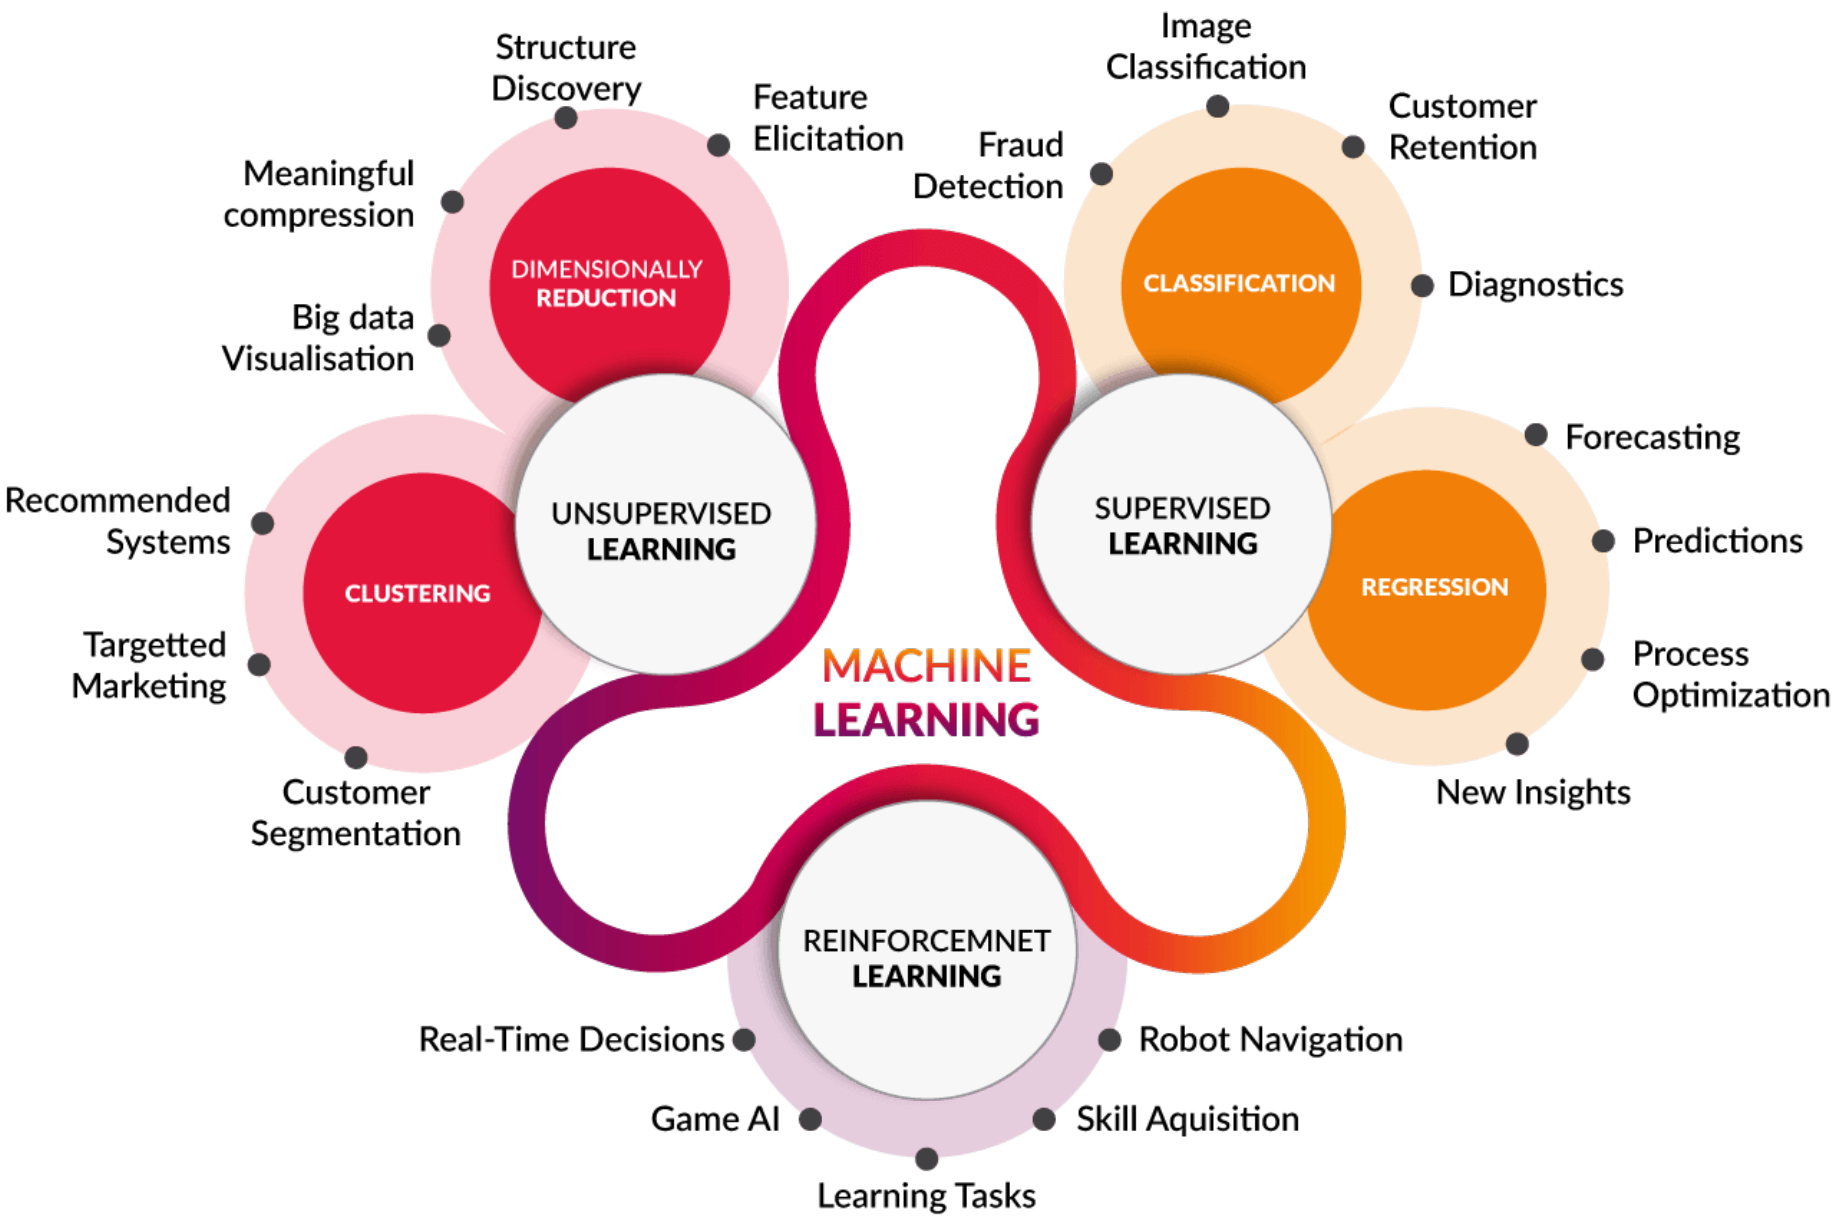
Tom Mitchell entrega una definición moderna de aprendizaje automático:

*"Programas informáticos que aprenden de la experiencia **E** con respecto a algun tipo de tareas **T** y medidas de rendimiento **P**, si su rendimiento en estas tareas en **T**, medido por **P**, mejora con la experiencia **E**".*

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Contexto ML


MACHINE LEARNING
UNSUPERVISED LEARNING
SUPERVISED LEARNING
REINFORCEMNET LEARNING
DIMENSIONALLY REDUCTION
CLUSTERING
CLASSIFICATION
REGRESSION
Structure Discovery
Feature Elicitation
Meaningful compression
Big data Visualisation
Image Classification
Customer Retention
Fraud Detection
Diagnostics
Recommended Systems
Targetted Marketing
Customer Segmentation
Forecasting
Predictions
Process Optimization
New Insights
Real-Time Decisions
Robot Navigation
Game AI
Skill Aquisition
Learning Tasks

Contexto ML


Regresión Lineal
SOCIEDAD ECUATORIANA DE ESTADISTICA
Modelo lineal usando optimización de mínimos cuadrado
Aprendizaje supervisado, entrenando el modelo mediante gradiente descendente que usa la derivada parcial de una función de costo igual a la suma de los errores cuadráticos
Original de @hadoopymemes | Traducido por @socecuest | Da el crédito

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Regresión

- La regresión es una *tarea* de aprendizaje supervisado, donde el objetivo es predecir resultados con **valores continuos**.
- A partir de una serie de variables llamadas **predictoras** (características) y variable(s) de respuesta continua llamadas **resultados/objetivos**, se trata de encontrar una ***relación*** entre dichas variables que permita predecir un futuro resultado.

Ejemplo

Supongamos que estamos interesados en predecir la nota de los estudiantes del curso en el examen 1. Si existe una **relación** entre *el tiempo dedicado* a estudiar para el examen y *la nota obtenida*, podriamos usarla como datos de entrenamiento para aprender un modelo que usa el tiempo de estudio para predecir las notas de los examenes de los futuros estudiantes que planean matricular este curso.

Regresión

- Si lo quieres para tu futuro,
¿Para qué le revisas el pasado?

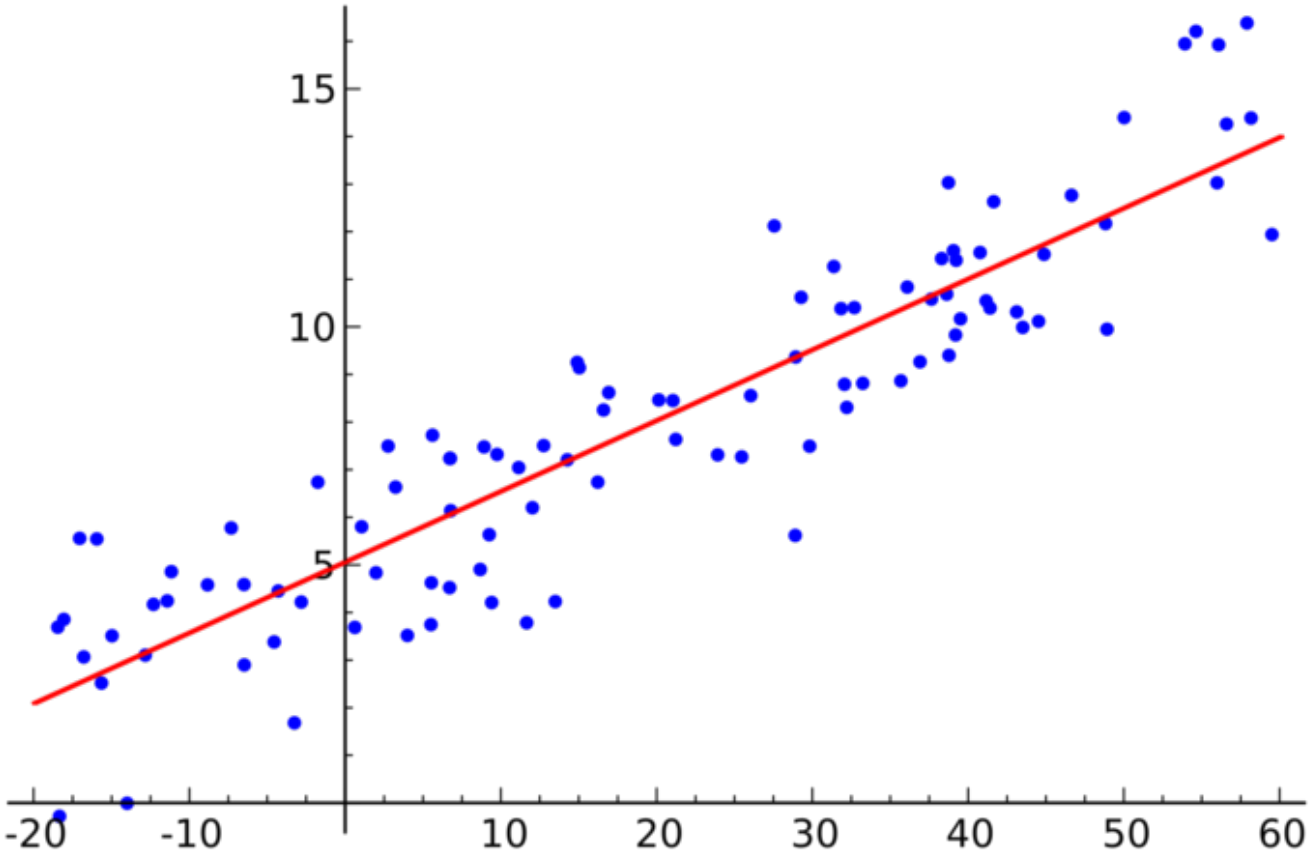
- Se le llama regresión lineal
en estadística y es
muy útil para predecir.

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Modelo de Regresión Lineal I

Forma Explicita



Modelo de Regresión Lineal II

Forma Explicita

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

donde:

- $\hat{y}$ es la predicción.
- n es el numero de características.
- x_i es el $i - esimo$ valor de la característica.
- θ_j es el $j - esimo$ parámetro del modelo.
- θ_0 es el **bias** del modelo (intercepto).

Modelo de Regresión Lineal I

Forma Matricial

$$\hat{y} = h_{\boldsymbol{\theta}}(\mathbf{x}) = \boldsymbol{\theta} \cdot \mathbf{x}$$

donde:

- $\boldsymbol{\theta}$ es el vector de parámetros del modelo.
- $\mathbf{x}$ es el vector de instancias de las características.
- $\boldsymbol{\theta} \cdot \mathbf{x}$ es el producto punto de los vectores $\boldsymbol{\theta}$ y $\mathbf{x}$.
- $h_{\boldsymbol{\theta}}$ es la función de hipótesis.

Nota

- x_0 es siempre igual a 1.
- $\boldsymbol{\theta}$ contiene el bias θ_0.

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Función de Costo

Definición

Una función de costo, es la encargada de medir el rendimiento (es decir, **cuantificar el error**) personificándolo en un solo valor. Se desea que esta función sea *convexa* y dependiendo de la *tarea*, esta puede cambiar.

Ejemplo

Mean Squared Error

$$MSE(\boldsymbol{X}, h_{\boldsymbol{\theta}}) = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{\theta}^T \mathbf{x}^{(i)} - y^{(i)})^2$$

El objetivo en un problema de ML/DL la mayoria de veces es encontrar los parámetros θ, tal que se **minimice la función de costo**.

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Formas de Ajuste/Entrenamiento

OLS - Ordinary Less Squares



- Solo requiere una iteración.
- Solución inmediata y optima.
- Sujeta a la inversión matricial y numero de muestras.

Gradiente Descendente - GD



- Requiere varias iteraciones.
- Solución buena.
- No depende de operaciones ni del número de muestras.

Ecuación Normal (Mínimos Cuadrados Ordinarios - OLS)

Definición

La **ecuación normal** es una forma directa (analítica) de encontrar los valores de $\boldsymbol{\theta}$

$$\hat{\boldsymbol{\theta}} = (\boldsymbol{X}^{\boldsymbol{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\boldsymbol{T}}\boldsymbol{Y}$$

Donde:

- $\hat{\boldsymbol{\theta}}$ es el valor de los parámetros $\boldsymbol{\theta}$ que minimiza la función de costo (MSE).
- $\boldsymbol{Y}$ es el vector (matriz) de valores objetivo (variable dependiente) que contiene y_1 hasta y_n
- $\boldsymbol{X}$ es el vector (matriz) de valores de las variables independientes (características) que contiene x_1 hasta x_n. Se le conoce también como **regresor**.

$$\boldsymbol{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \qquad \boldsymbol{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

Ecuación Normal (Mínimos Cuadrados Ordinarios - OLS)

Características

- Velocidad computacional por complejidad $O(N^3)$ para matrices n x n.
- Depende de la **invertibilidad** de X.
- Asume al solucionar que ya está en el valor mínimo de la función de costo.

$$MSE(\boldsymbol{X}, h_{\hat{\boldsymbol{\theta}}}) = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{\theta}^T \mathbf{X}^{(i)} - \mathrm{y}^{(i)})^2 = \|\mathbf{X}\cdot\hat{\boldsymbol{\theta}} - Y\|^2$$

$$\frac{\partial MSE(\boldsymbol{\theta})}{\partial\theta} = 0 \longrightarrow 2\mathbf{X}^T \cdot \|\mathbf{X}\cdot\boldsymbol{\theta} - Y\| = 0 \text{ (Crítico)}$$

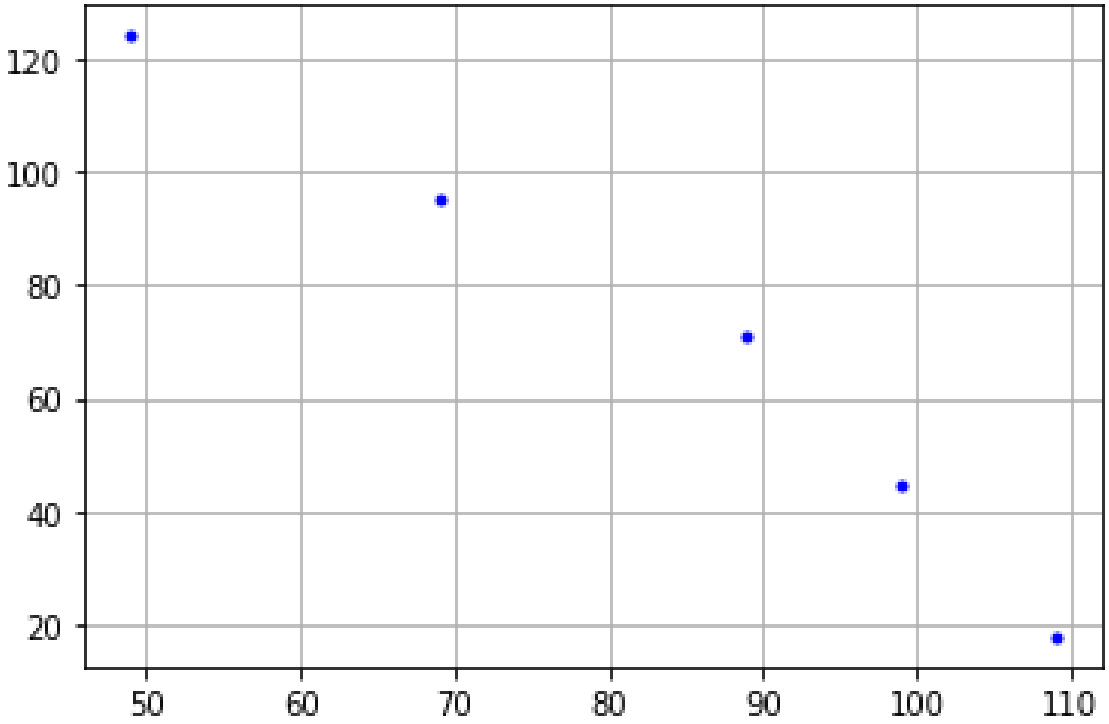
$$2\mathbf{X}^T \cdot \mathbf{X}\cdot\boldsymbol{\theta} - 2\mathbf{X}^T \cdot Y = 0$$

$$2\mathbf{X}^T \cdot \mathbf{X}\cdot\hat{\boldsymbol{\theta}} = 2\mathbf{X}^T \cdot y \longrightarrow \mathbf{X}^T \cdot \mathbf{X}\cdot\hat{\boldsymbol{\theta}} = \mathbf{X}^T \cdot Y \quad \text{Despejando } \hat{\boldsymbol{\theta}}$$

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \cdot \mathbf{X})^{-1}\mathbf{X}^T \cdot Y$$

Ecuación Normal (Mínimos Cuadrados Ordinarios - OLS)

Price(x)	Demand(y)
49	124
69	95
89	71
99	45
109	18



$$\hat{\boldsymbol{\theta}} = (\boldsymbol{X^T X})^{-1} \boldsymbol{X^T Y}$$

$$\boldsymbol{Y} = \begin{bmatrix} 124 \\ 95 \\ 71 \\ 45 \\ 18 \end{bmatrix} \quad \boldsymbol{X} = \begin{bmatrix} 1 & 49 \\ 1 & 69 \\ 1 & 89 \\ 1 & 99 \\ 1 & 109 \end{bmatrix}$$

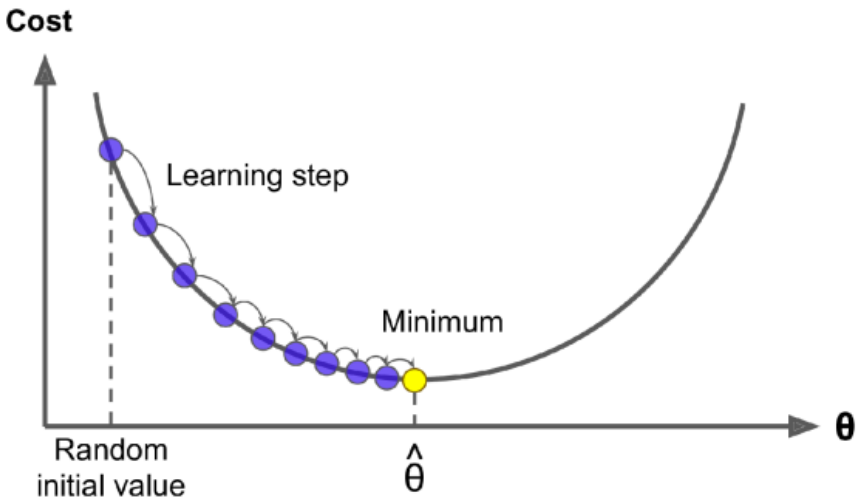
$$\hat{\theta} = \frac{1}{11600} \begin{bmatrix} 36765 & -415 \\ -415 & 5 \end{bmatrix} \cdot \begin{bmatrix} 353 \\ 25367 \end{bmatrix} \approx \begin{bmatrix} 211 \\ -1{,}7 \end{bmatrix}$$

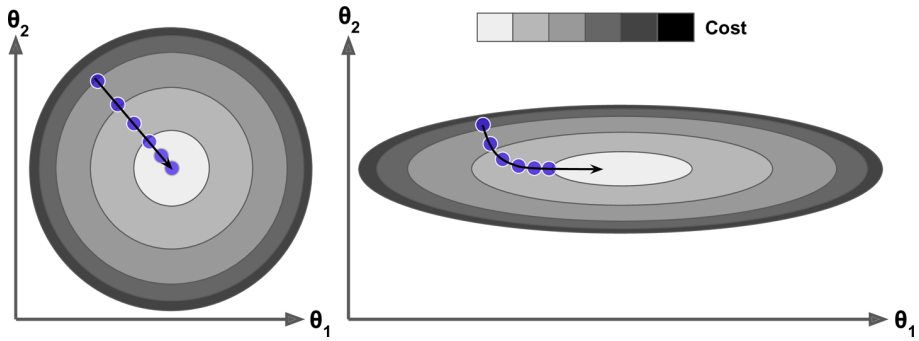
$$\hat{y} = 211 - 1{,}7x$$

Gradiente Descendente

Definición

El gradiente descendente un algoritmo de optimización que permite encontrar de forma automática el **mínimo de una función de costo (convexa)** desde un *punto de partida*.
Para ello, hace uso de el **gradiente** (o derivada) de dicha función, que permite "guiar" al algoritmo para de manera **progresiva** acercarse al mínimo ideal de dicha función.





Gradiente Descendente

Características

- Su convergencia depende directamente de la tasa de aprendizaje η.
- No asume su presencia en el mínimo, tiene un punto de partida especifico y desde alli busca a traves del gradiente.
- La complejidad computacional es $O(kN^2)$
- Es un algoritmo transversal, es decir al cambiar la función de costo, puede cambiar la tarea que realice.
- Clave el **escalamiento** de los datos.

Gradiente de la función de costo:

$$\nabla_{\boldsymbol{\theta}} MSE(\boldsymbol{\theta}) = \begin{bmatrix} \frac{\partial}{\partial \theta_0} MSE(\boldsymbol{\theta}) \\ \frac{\partial}{\partial \theta_1} MSE(\boldsymbol{\theta}) \\ \vdots \\ \frac{\partial}{\partial \theta_n} MSE(\boldsymbol{\theta}) \end{bmatrix} = \frac{2}{m} \mathbf{X}^T (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$$

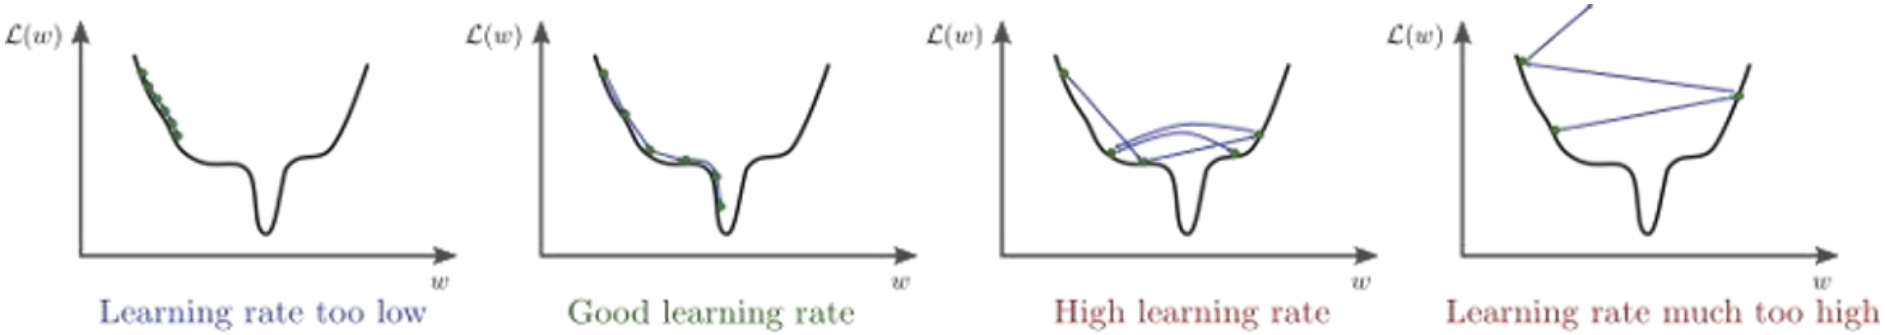
Actualización del gradiente:

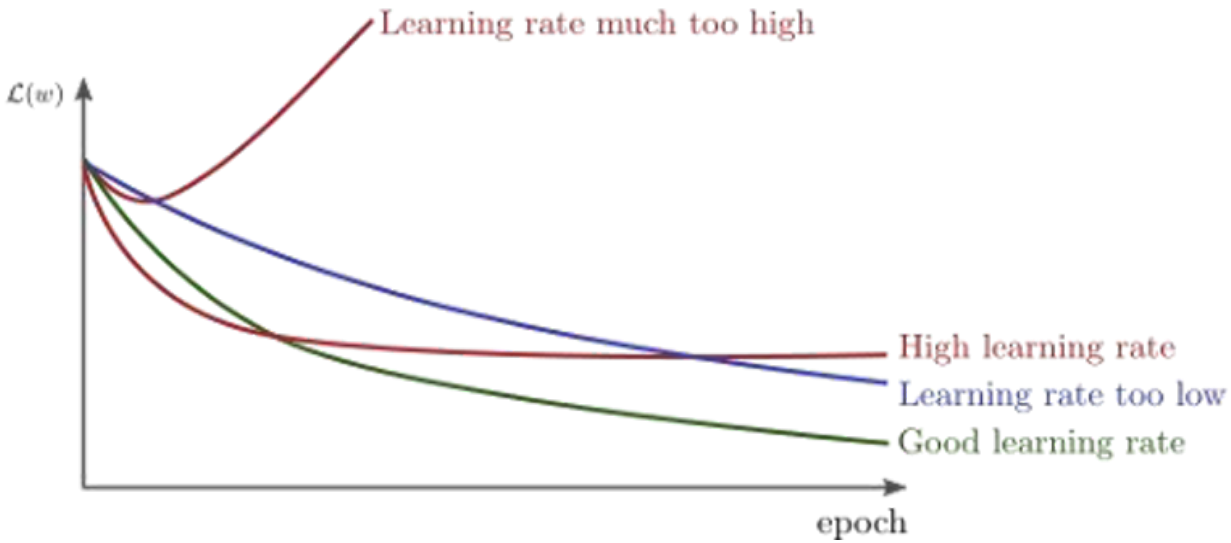
$$\boldsymbol{\theta}^{(\text{next step})} = \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} MSE(\boldsymbol{\theta})$$

Clave

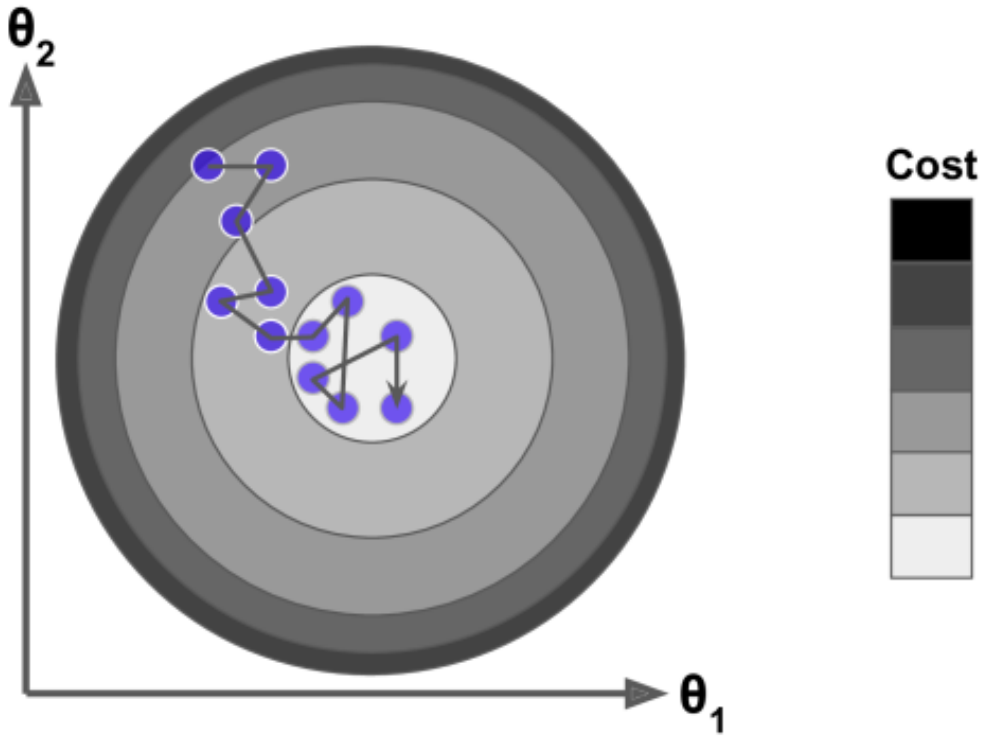
Este algoritmo usa todas las muestras disponibles de manera ordenada en cada iteración.

Gradiente Descendente





Gradiente Descendente Estocástico

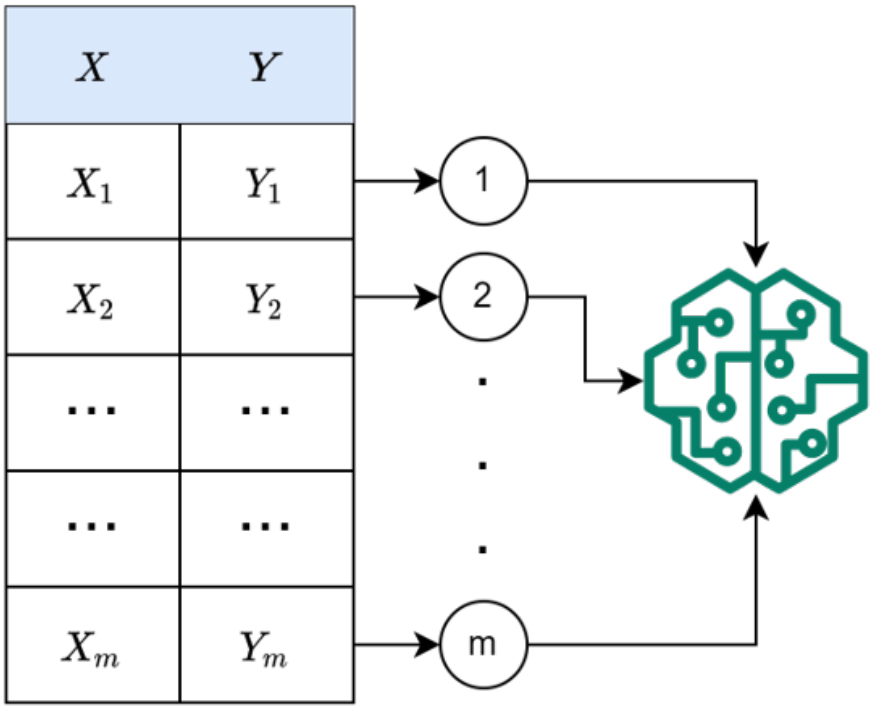


- Se selecciona de manera aleatoria una parte de los datos de entrenamiento para calcular el gradiente.
- Es menos *regular* que el gradiente convencional.
- Permite encontrar valores mínimos de los parámetros, pero no los óptimos.
- Debido a su aleatoriedad, tiene mayor probabilidad de encontrar el mínimo global en funciones no convexas.

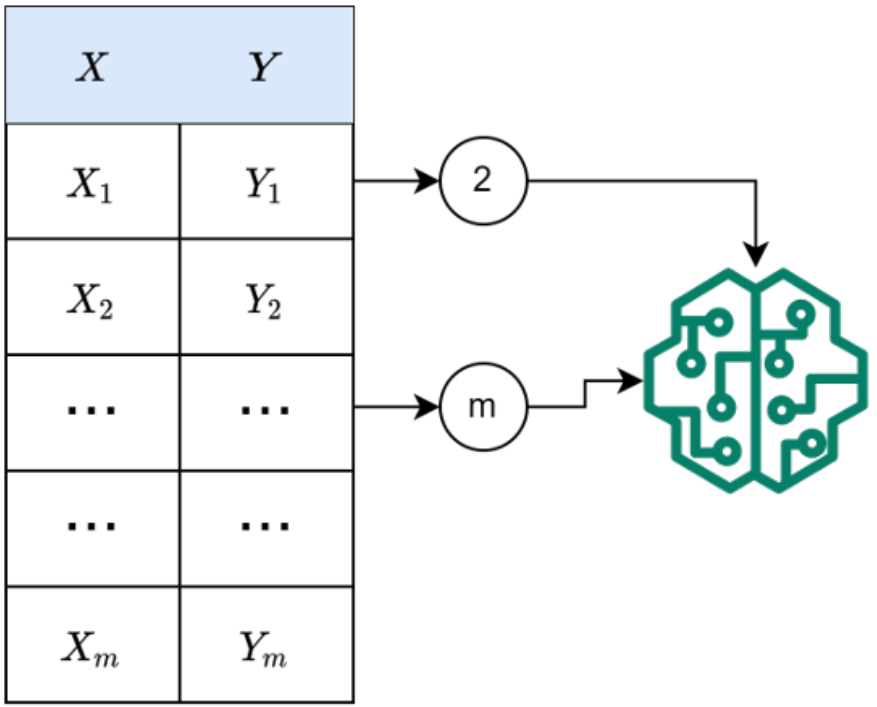
Gradiente Descendente Estocástico

Diferencias vs GD ordinario

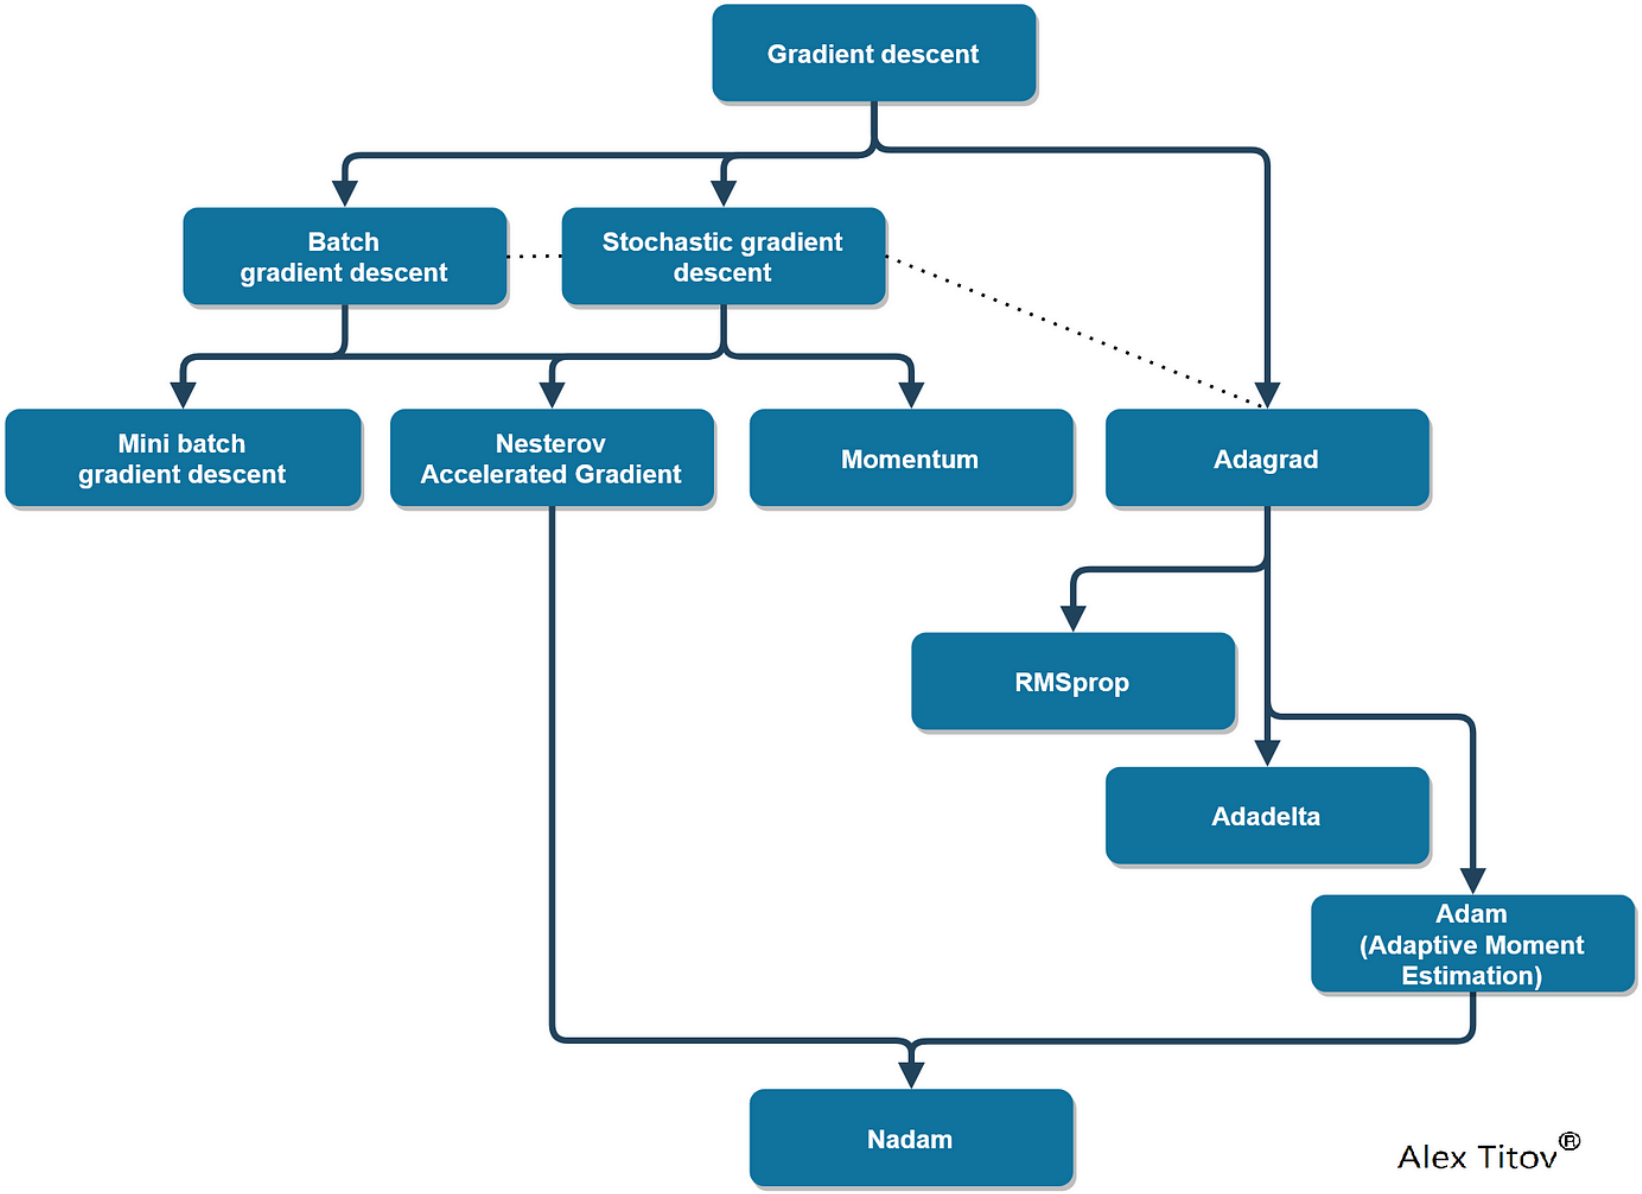
Gradiente Descendente (GD)



Gradiente Descendente Estocástico (SGD)



Gradiente Descendente (Familia)

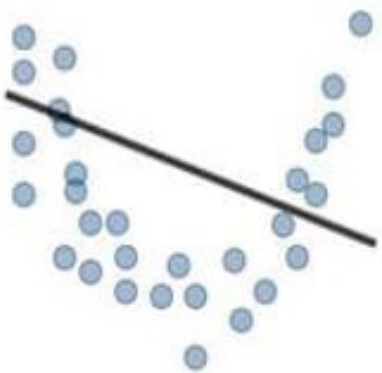


Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Regularización (I)

Problemas de ajuste/entrenamiento

	Underfitting	Just right	Overfitting
Symptoms	• High training error • Training error close to test error • High bias	• Training error slightly lower than test error	• Very low training error • Training error much lower than test error • High variance
Regression illustration			

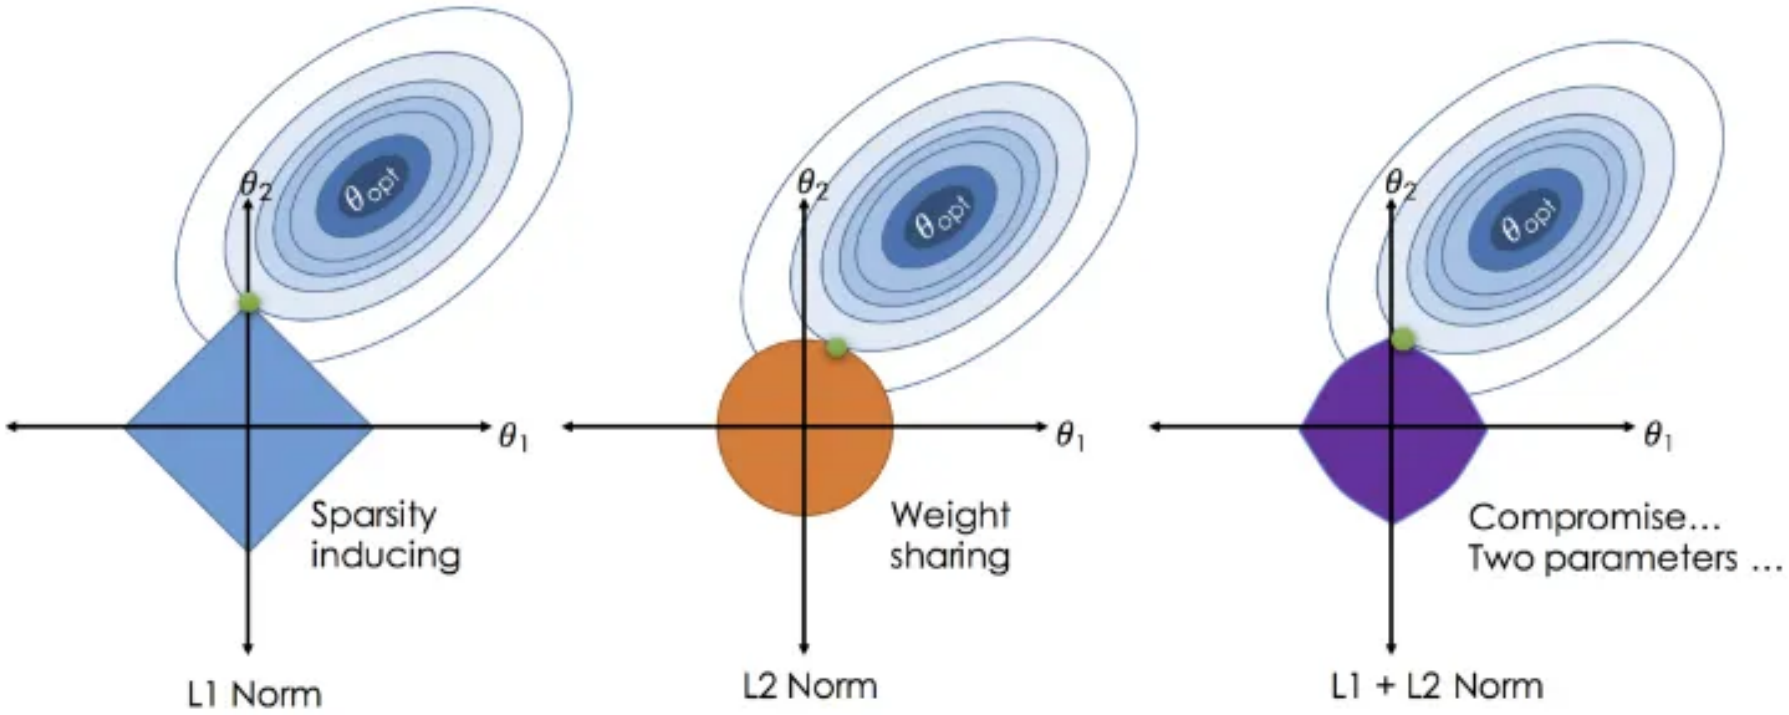
- **Overfitting**: problema común en ML, donde un modelo funciona bien con los datos de entrenamiento, pero no es capaz de funcionar bien ante datos nunca vistos (datos de validacion).
- **Underfitting**: Opuesto al overfitting, en donde un modelo no funciona bien ni con los datos de entrenamiento ni los de validación.

Regularización (II)

Solución

Regularización

$$J(\theta) = MSE(\theta) + \alpha \frac{1}{2} \sum_{i=1}^{n} \theta_i^2$$



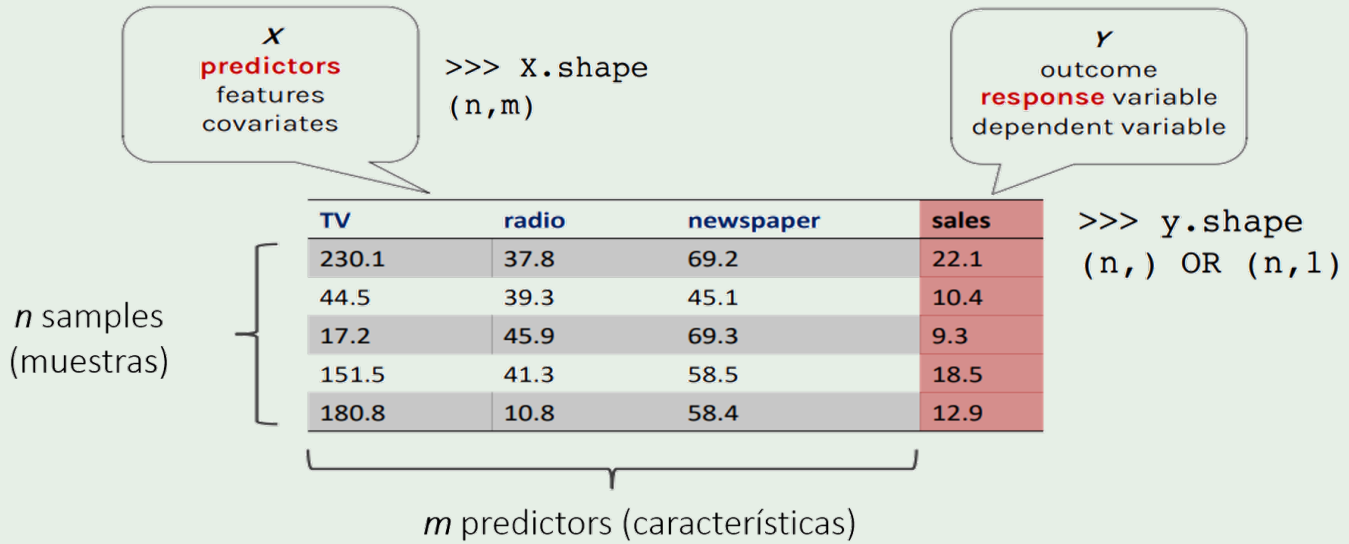
Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Regresión lineal con scikit-learn

Ejemplo

El conjunto de datos de publicidad consiste en las ventas de un producto en 200 mercados diferentes, y los presupuestos de publicidad para producto en cada uno de esos mercados para tres medios diferentes: TV, radio y prensa. Todo se da en unidades de $ 1000.

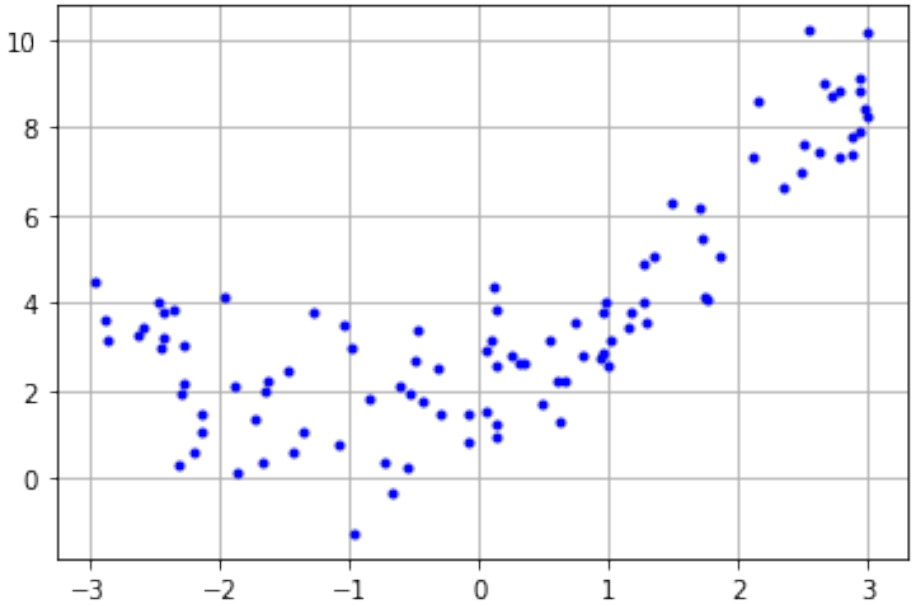


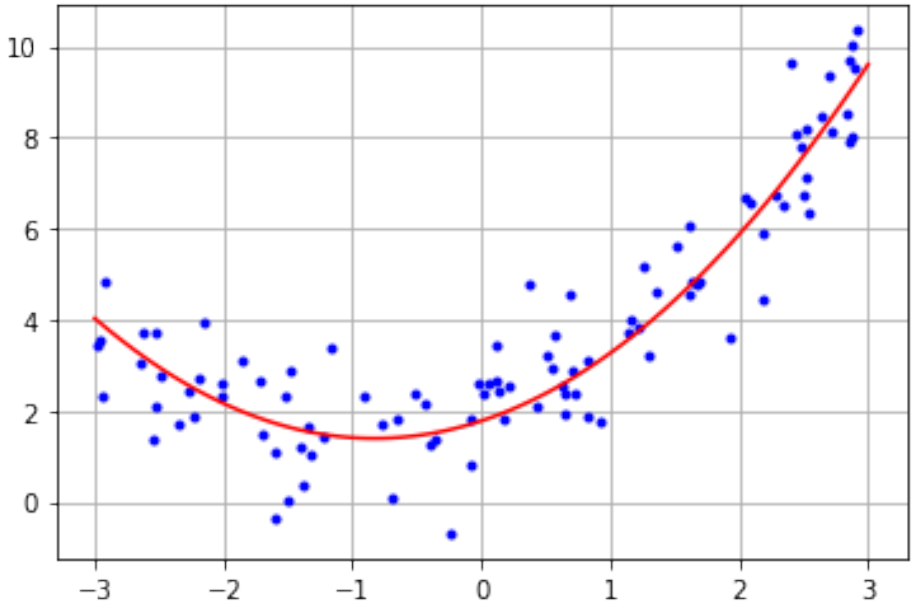
TV	radio	newspaper	sales
230.1	37.8	69.2	22.1
44.5	39.3	45.1	10.4
17.2	45.9	69.3	9.3
151.5	41.3	58.5	18.5
180.8	10.8	58.4	12.9

Agenda

1. Machine Learning
2. Problemas de Regresión
   - Contexto
   - Regresión
   - Modelo de Regresión Lineal
     - Forma Explicita
     - Forma Matricial
3. Ajuste - Entrenamiento
   - Función de Costo
   - Alternativas
     - Ecuación Normal
     - Gradiente Descendente
   - Regularizacion
   - Usando la librería scikit-learn
   - Regresión Polinomial
4. Referencias

Regresión Polinomial





La técnica consiste en adicionar una nueva variable predictora la cual puede ser el cuadrado de la variable predictora original, multiplicacion entre variables, y cualquier otra posibilidad que agregue no linealidad al modelo.

$$\hat{y} = \theta_0 + \theta_1 x_1 \rightarrow \hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_1^2$$

Regresión Polinomial

Implicaciones de complejidad

Lineal Simple $\begin{bmatrix} 1 & x_1^{(1)} \\ 1 & x_1^{(2)} \\ \vdots & \vdots \\ 1 & x_1^{(m)} \end{bmatrix}$

$\begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \vdots & \vdots & \\ 1 & x_1^{(m)} & x_2^{(m)} & \cdots & x_n^{(m)} \end{bmatrix}$ Lineal Múltiple

Polinomial $\begin{bmatrix} 1 & X_{1(1)} & X_{1(1)}^2 & \cdots & X_{1(1)}^p & X_{2(1)}^2 & \cdots & X_{n(1)}^p \\ 1 & X_{1(2)} & X_{1(2)}^2 & \cdots & X_{1(2)}^p & X_{2(2)}^2 & \cdots & X_{n(2)}^p \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1(m)} & X_{1(m)} & \cdots & X_{1(m)}^p & X_{2(m)}^2 & \cdots & X_{n(m)}^p \end{bmatrix}$

Orden p
Características n
Muestras m

La complejidad en este tipo de regresion aumenta dado el incremento del tamaño del regresor propiamente, lo que puede llevar en muchas ocasiones al sobreajuste (sobreentreno)

Referencias

https://medium.com/swlh/linear-regression-from-scratch-4ac1cc666ee2
https://scikit-learn.org/stable/index.html